

UNIVERSITÀ DEGLI STUDI DI SALERNO

DIPARTIMENTO DI INFORMATICA



Corso di Laurea Magistrale in Informatica

Curriculum DATA SCIENCE & MACHINE LEARNING

Titolo

Relatore:

Ch.mo Prof.

Fabio PALOMBA

Candidato:

Marco DI MAIO

Mat. 0522501704

Correlatore:

Ch.mo Prof.

...

ANNO ACCADEMICO 2024/2025

Dedicata a ...

CONTENTS

1	Introduzione	7
1.1	Contesto generale	7
1.2	PENTION-S e PENTION-M: due sistemi complementari . . .	10
1.3	Obiettivi della tesi	11
1.4	Metodologia adottata	13
1.5	Struttura della tesi	14
2	Background, Stato dell'Arte e Fondamenti	17
2.1	New Psychoactive Substances (NPS)	17
2.2	Spettrometria di Massa a Ionizzazione Elettronica	18
2.3	Dataset e Banche Dati per la Caratterizzazione delle NPS . .	19
2.3.1	Panoramica delle Fonti di Dati EI	20
2.3.2	SWGDRUG	20
2.3.3	MoNA – MassBank of North America	20
2.3.4	SDBS	21
2.3.5	Problemi di Merging e Normalizzazione	21
2.3.6	Dataset Finale: PENTION_EI_Complete	21
2.4	Simulazione della Dispersione Chimica in Ambienti Urbani . .	23
2.5	Physics-Informed Machine Learning	23
2.6	MLOps in Sistemi Cyber-Fisici e Contesti Forensi	25

CONTENTS

2.7	PENTION-S: Architettura di Riferimento	26
3	Metodologia: Design Science Research (DSR)	27
3.1	Perché adottare il Design Science	27
3.2	Fasi del Design Science Research	28
3.3	Applicazione del DSR al progetto PENTION-M	29
3.3.1	Identificazione del problema	29
3.3.2	Analisi preliminare del sistema PENTION-S	30
3.3.3	Obiettivi della soluzione	30
3.3.4	Progettazione e sviluppo	31
3.3.5	Dimostrazione	32
3.3.6	Valutazione	32
3.3.7	Comunicazione	32
3.4	Requirements Engineering	33
3.4.1	Stakeholder coinvolti	33
3.4.2	Strumenti e protocollo di elicitazione	33
3.4.3	Classificazione dei requisiti	34
3.4.4	Sintesi dei requisiti emersi	34
3.5	Iterazioni dell'artefatto e tracciabilità ai requisiti	37
3.5.1	Versione 1: prototipo abilitante e pipeline simulata . .	37
3.5.2	Versione 2: integrazione fisica e modelli PIML	38
3.5.3	Versione 3: calibrazione delle confidenze e controllo dell'over- confidence	39
3.5.4	Versione 4: logging forense e tracciabilità delle evidenze	39
3.5.5	Iterazione finale: consolidamento dell'architettura PIML e MLOps	40
3.6	Data Flow Model del processo DSR	41
3.7	Discussione: validazione by construction e collegamento ai capi- toli successivi	43
4	Architettura e Realizzazione di PENTION-M	44
4.1	Introduzione al Capitolo	44

CONTENTS

4.2	Visione architetturale complessiva di PENTION-M	45
4.3	Architettura a 8 Layer di PENTION-M	47
4.4	Flusso operativo end-to-end (vista runtime)	49
4.5	Layer 0 – Edge I/O e simulazione dei sensori	50
4.6	Layer 1 – Data Ingestion e validazione	52
4.6.1	Struttura del payload e validazione iniziale	53
4.6.2	Costruzione dell’evento unificato	53
4.6.3	Orchestrazione dei servizi downstream	54
4.6.4	Integrazione con Monitoring e ModelOps	54
4.6.5	Logging forense e produzione delle evidenze	55
4.7	Layer 2 – Feature fisiche e PIML Feature Layer	55
4.7.1	Feature meteorologiche e parametri fisici di dispersione	56
4.7.2	Maschere urbane e contesto geometrico (building map)	58
4.7.3	Feature derivate per la localizzazione della sorgente	59
4.8	Layer 3 – Inference Services	60
4.8.1	Servizio di classificazione NPS (EI)	61
4.8.2	Simulazione fisica della dispersione	64
4.8.3	Modello PIML di correzione della dispersione	65
4.8.4	Modello di localizzazione della sorgente	67
4.9	Layer 4 – Monitoring e Telemetry	70
4.9.1	Ruolo del monitoring nel contesto PENTION-M	70
4.9.2	Struttura dell’evento di monitoring	71
4.9.3	Monitoraggio della latenza	71
4.9.4	Drift fisicamente informato	72
4.9.5	Stabilità e confidenza delle predizioni	73
4.9.6	Persistenza e auditabilità dei log	73
4.10	Layer 5 – ModelOps e logging forense	73
4.10.1	Ruolo del ModelOps nel contesto PENTION-M	74
4.10.2	Versioning dei modelli e audit trail	75
4.10.3	Logging forense e struttura del bundle	76
4.10.4	Firma digitale e verifica dell’integrità	76

CONTENTS

4.10.5	Chain of custody digitale	77
4.10.6	Collegamento con la validazione by construction	78
4.11	Layer 6 – Interfaccia utente operativa e demo live	78
4.11.1	Componenti visuali e logica di interazione	79
4.11.2	Aggiornamento real-time e integrazione con la pipeline	80
4.11.3	Report operativo e collegamento alle evidenze forensi .	81
4.11.4	Discussione: ruolo della UI nella validazione by-construction	81
4.12	Layer 7 – Forensic Export e reporting	82
4.12.1	Export in formato JSON: bundle forense verificabile .	82
4.12.2	Export in formato PDF: report human-readable	83
4.12.3	Riproducibilità e audit esterno	83
4.13	Discussione architetturale e trade-off	84
4.13.1	Fisica vs fedeltà del modello	85
4.13.2	PIML vs approcci puramente data-driven	85
4.13.3	Accuratezza vs robustezza operativa	86
4.13.4	Simulazione vs dati reali	86
4.14	Collegamento al Capitolo di Valutazione	87
5	Validazione dell’artefatto	89
5.1	Inquadramento della validazione secondo il Design Science Research	89
5.2	Validazione tramite stakeholder	92
5.2.1	Feedback delle Law Enforcement Agencies	93
5.2.2	Feedback dei partner industriali e di progetto	94
5.2.3	Feedback accademico e supervisione scientifica	94
5.3	Validazione tecnica dell’artefatto	95
5.3.1	Validazione delle prestazioni runtime	96
5.3.2	Validazione dei modelli PIML	98
5.3.3	Validazione della localizzazione della sorgente	101
5.3.4	Validazione della classificazione NPS	107
5.3.5	Effetto del Temperature Scaling adattivo	112

CONTENTS

5.4	Experience Report	114
5.4.1	Contesto dell'esperienza di sviluppo	115
5.4.2	Problemi emersi durante la costruzione dell'artefatto	115
5.4.3	Iterazioni progettuali come forma di validazione	116
5.4.4	Lezioni metodologiche apprese	117
5.5	Discussione complessiva dei risultati	118
6	Limitazioni e sviluppi futuri	120
	Acknowledgements	121
	References	122
	List of Figures	126
	List of Tables	128

CHAPTER 1

INTRODUZIONE

1.1 Contesto generale

Negli ultimi anni la diffusione delle *New Psychoactive Substances* (NPS) ha rappresentato una delle sfide più complesse per le forze dell'ordine e le agenzie doganali europee. Le NPS sono molecole sintetiche progettate per imitare gli effetti di sostanze stupefacenti già note, ma con una struttura chimica modificata che le rende difficili da rilevare attraverso i metodi tradizionali. La loro rapida evoluzione, unita alla facilità di produzione in laboratori clandestini di piccole dimensioni, determina un contesto operativo caratterizzato da elevata incertezza e da un continuo aggiornamento dei repertori analitici.

Dal punto di vista chimico e operativo, una caratteristica distintiva delle NPS è la loro capacità di diffondersi nell'ambiente in forma di tracce volatili o aerosol durante le fasi di produzione, manipolazione e confezionamento. Tali emissioni, pur avvenendo a concentrazioni estremamente basse, possono costituire un indicatore rilevante della presenza di attività illecite, soprattutto in prossimità di laboratori clandestini o siti di trasformazione temporanei.

A differenza delle sostanze tradizionali, la produzione di NPS è spesso

1. INTRODUZIONE

associata a laboratori di piccole dimensioni, facilmente riconfigurabili e potenzialmente mobili, che operano in ambienti urbani o peri-urbani. Questo rende inefficaci molte delle strategie di contrasto basate su controlli statici o su ispezioni mirate esclusivamente ai punti di distribuzione finale, spostando il focus delle operazioni investigative verso il rilevamento precoce delle emissioni ambientali.

La possibilità di intercettare segnali chimici dispersi nell'aria rappresenta pertanto un cambio di paradigma nel contrasto alla produzione di NPS, consentendo alle forze dell'ordine di individuare potenziali sorgenti prima che le sostanze entrino nella catena di distribuzione.

Queste caratteristiche rendono evidente come il problema del rilevamento delle NPS non possa essere affrontato esclusivamente attraverso analisi di laboratorio o controlli a posteriori, ma richieda strumenti capaci di operare direttamente sul campo, in tempo reale e in condizioni ambientali non controllate.

In scenari reali, gli operatori devono spesso intervenire in ambienti dinamici e poco strutturati, come aree urbane densamente popolate o zone industriali dismesse, dove la presenza di sostanze volatili o residui chimici può costituire un indicatore cruciale di attività illecite. In questo contesto, la possibilità di impiegare sistemi mobili in grado di rilevare, analizzare e interpretare in tempo reale la presenza di composti chimici rappresenta un obiettivo di grande rilevanza sia scientifica sia operativa.

A livello europeo, il fenomeno delle sostanze sintetiche rappresenta una minaccia crescente sia per la sicurezza pubblica sia per la salute dei cittadini. Negli ultimi anni, organizzazioni criminali distribuite in diversi Paesi membri hanno adottato modelli produttivi estremamente flessibili, fondati su piccoli laboratori mobili, precursori facilmente reperibili e tecniche chimiche adattive. Questa dinamica rende la produzione di NPS difficilmente individuabile e consente una rapida introduzione di nuove varianti, spesso non ancora incluse nei repertori analitici ufficiali delle agenzie governative.

Tale scenario è ulteriormente aggravato dal fatto che molte attività di

1. INTRODUZIONE

produzione e distribuzione avvengono in aree urbane complesse, caratterizzate da elevata densità abitativa e da infrastrutture fisiche che ostacolano sia le operazioni di rilevamento sia la modellazione della dispersione di sostanze volatili. Le forze dell'ordine europee hanno quindi espresso la necessità di strumenti capaci di supportare il processo decisionale sul campo, fornendo analisi affidabili, contestualizzate e rapidamente verificabili.

In risposta a queste esigenze, il progetto PENTION si propone di sviluppare una piattaforma digitale e fisica orientata al monitoraggio, alla modellazione e al rilevamento precoce di attività legate alla sintesi di droghe sintetiche. L'iniziativa mira a combinare modelli predittivi, tecniche di analisi automatizzata, simulazioni fisiche e strumenti di supporto investigativo, contribuendo a colmare il gap tecnologico attualmente presente nelle operazioni delle LEAs europee.

Tuttavia, l'identificazione automatica delle NPS presenta diversi ostacoli: gli spettri di massa ottenuti sul campo possono essere rumorosi, parziali o deteriorati; le condizioni ambientali influenzano fortemente la dispersione chimica; e molti strumenti attuali non sono pensati per fornire risultati *tracciabili* o utilizzabili in un contesto investigativo. È dunque necessario progettare sistemi che integrino modelli fisici, tecniche di machine learning, simulazioni ambientali e meccanismi di audit forense, in modo da garantire robustezza, spiegabilità e affidabilità del processo decisionale.

Uno degli aspetti critici evidenziati dagli operatori del settore riguarda la mancanza di sistemi integrati in grado di combinare misurazioni ambientali, modelli fisici e algoritmi di intelligenza artificiale all'interno di un'unica piattaforma operativa. Le soluzioni attualmente disponibili sono spesso frammentate, non interoperabili e prive di un meccanismo strutturato di tracciabilità che consenta la validazione forense dei risultati. Inoltre, la maggior parte degli strumenti commerciali non è progettata per un utilizzo mobile né per l'analisi contestuale in aree urbane reali, limitando notevolmente la capacità delle agenzie di condurre operazioni dinamiche e tempestive.

La necessità di superare tali limitazioni richiede la progettazione

di un sistema capace di integrare diverse fonti informative, aggiornarsi dinamicamente durante la perlustrazione del territorio e produrre evidenze digitali verificabili. È proprio su questa esigenza che si fonda la visione del progetto PENTION, orientato alla creazione di una piattaforma cyber-fisica avanzata per il rilevamento e l'interpretazione di fenomeni chimici riconducibili alla produzione di sostanze sintetiche.

1.2 PENTION-S e PENTION-M: due sistemi complementari

Il progetto PENTION prevede lo sviluppo coordinato di due piattaforme autonome e complementari, ciascuna progettata per rispondere a esigenze operative specifiche delle forze dell'ordine europee. PENTION-S è orientato al monitoraggio statico e continuo attraverso l'installazione di sensori fissi in infrastrutture critiche quali aeroporti, centri logistici, uffici postali e aree ad accesso controllato. In tali contesti, la possibilità di acquisire misurazioni da sorgenti posizionate stabilmente consente analisi regolari, accumulo di evidenze nel tempo e rilevamento precoce di anomalie chimiche in ambienti generalmente strutturati e prevedibili.

PENTION-M, invece, nasce per affrontare scenari radicalmente diversi, caratterizzati da mobilità, variabilità ambientale e necessità di intervento rapido. Le attività di perlustrazione urbana, i controlli in prossimità di porti e confini, le investigazioni in aree industriali o rurali e, più in generale, tutte le situazioni in cui gli operatori devono spostarsi attivamente sul territorio richiedono una piattaforma capace di raccogliere, elaborare e interpretare dati in tempo reale durante il movimento. In questi scenari, la mobilità non è un'opzione accessoria, ma un requisito essenziale.

Pur condividendo alcune finalità generali del progetto PENTION — in particolare il rilevamento precoce di sostanze chimiche e il supporto data-driven alle decisioni operative — i due sistemi non vanno intesi come versioni successive dello stesso artefatto software. Essi rappresentano due risposte

progettuali distinte a problemi differenti: stabilità e continuità nel caso di PENTION-S, flessibilità e reattività nel caso di PENTION-M.

Nel contesto di questa tesi, l'analisi iniziale di PENTION-S ha svolto un ruolo conoscitivo importante per comprendere le logiche di modellazione, le assunzioni fisiche e le scelte architettureali alla base del sistema statico. Tuttavia, PENTION-M è stato progettato come un artefatto indipendente, dotato di un'architettura dedicata, di modelli specifici per la mobilità e di una pipeline operativa completamente ripensata per l'elaborazione di dati raccolti durante il movimento del veicolo.

1.3 Obiettivi della tesi

L'obiettivo principale di questa tesi è la progettazione e la realizzazione di un sistema in grado di simulare, in maniera realistica e operativamente coerente, il comportamento di un laboratorio mobile dedicato al rilevamento e all'analisi di sostanze psicoattive emergenti. La piattaforma risultante, denominata PENTION-M, è stata progettata come sistema autonomo dedicato al rilevamento mobile, distinto ma complementare rispetto a PENTION-S, con cui condivide solo alcuni principi concettuali individuati nelle fasi preliminari dello studio.

A partire da questo obiettivo generale, il lavoro può essere articolato in una serie di obiettivi specifici:

- **Progettare un modello di simulazione fisica realistico** della dispersione di sostanze chimiche in ambiente urbano, capace di adattarsi a condizioni meteo variabili e alla presenza di edifici, integrando una rappresentazione dinamica del movimento del veicolo.
- **Integrare modelli *Physics-Informed Machine Learning* (PIML)** per la correzione e l'interpretazione delle mappe di dispersione, garantendo coerenza con i vincoli fisici del dominio operativo.
- **Sviluppare un modello di localizzazione della sorgente** basato su

1. INTRODUZIONE

informazioni fisiche derivate, in grado di stimare la posizione del rilascio con stabilità e robustezza.

- **Costruire un classificatore di sostanze NPS affidabile**, facendo uso di un dataset ampio e derivato da molteplici fonti, e dotato di un meccanismo di calibrazione probabilistica adattiva per la riduzione dell'overconfidence.
- **Progettare una pipeline MLOps completa**, comprendente ingestion, validazione, calcolo delle feature fisiche, inferenza dei modelli, monitoring dei parametri operativi (latenza, drift, versione del modello, confidenza) e strategie per il retraining.
- **Realizzare un sistema di logging forense e chain-of-custody**, tramite la generazione di un bundle di evidenze digitali contenente dati, modelli, parametri e firme crittografiche, con l'obiettivo di garantire tracciabilità, integrità e verificabilità dell'intero processo.
- **Sviluppare un'interfaccia interattiva in tempo reale** che consenta di orchestrare la simulazione, visualizzare i risultati e riprodurre fedelmente il flusso operativo di un laboratorio mobile.

Questi obiettivi si collocano in continuità con le finalità più ampie del progetto PENTION, che include tra le sue linee strategiche la riduzione della produzione di droghe sintetiche in Europa, il potenziamento delle capacità di identificazione precoce di precursori e sottoprodotti chimici, e il supporto alle agenzie di sicurezza attraverso strumenti affidabili, spiegabili e legalmente ammissibili. Il sistema proposto in questa tesi contribuisce a tali finalità fornendo un prototipo operativo che integra in modo coerente simulazione fisica, analisi predittiva e generazione di evidenze digitali verificabili.

Nel loro insieme, questi obiettivi concorrono alla costruzione di un prototipo avanzato che unisce aspetti di simulazione fisica, apprendimento automatico, ingegneria del software, modellazione operativa e requisiti forensi. La tesi si colloca dunque all'intersezione tra sistemi cyber-fisici, intelligenza

artificiale applicata e tecnologie di supporto alle attività investigative, con l'intento di offrire un contributo concreto allo sviluppo di piattaforme intelligenti per la sicurezza pubblica.

1.4 Metodologia adottata

La natura del problema affrontato in questa tesi, che coinvolge aspetti di simulazione fisica, modellazione predittiva, progettazione software e requisiti operativi provenienti da contesti investigativi reali, richiede un approccio metodologico capace di integrare attività di analisi, progettazione, implementazione e valutazione in un ciclo iterativo e guidato dagli stakeholder. Per questo motivo il lavoro si colloca all'interno del paradigma della *Design Science Research* (DSR), una metodologia ampiamente adottata nella ricerca ingegneristica e informatica per la costruzione di artefatti innovativi orientati alla soluzione di problemi concreti.

La DSR pone al centro del processo la progettazione di un artefatto—nel caso di questa tesi, il sistema PENTION-M—inteso come combinazione strutturata di modelli fisici, algoritmi di machine learning, pipeline operative e componenti software. L'efficacia dell'artefatto non deriva unicamente dalla sua implementazione tecnica, ma dalla sua capacità di rispondere ai requisiti emersi da un contesto reale, e dalla possibilità di valutarlo attraverso iterazioni successive che riflettono feedback, vincoli e obiettivi operativi.

In questo lavoro, la metodologia DSR si articola in tre dimensioni principali:

- **Relevance**, ovvero la rilevanza del problema: il rilevamento di sostanze NPS richiede strumenti robusti, tracciabili e operativamente affidabili, come confermato dalle attività di Requirements Engineering condotte con le forze dell'ordine olandesi e con i partner del progetto;
- **Rigor**, ovvero il rigore scientifico: il sistema è fondato su basi teoriche consolidate, quali modelli di dispersione gaussiana, metodologie PIML,

tecniche di calibrazione probabilistica e principi di MLOps per l'analisi forense e la gestione del ciclo di vita dei modelli;

- **Design & Evaluation**, ossia progettazione e valutazione iterativa: l'artefatto è stato sviluppato attraverso versioni incrementali, ciascuna valutata tramite feedback degli stakeholder, analisi dei risultati e verifica della coerenza fisica e funzionale.

Un ulteriore elemento distintivo del processo adottato riguarda la forte interdisciplinarietà del progetto, che combina competenze di chimica analitica, modellazione atmosferica, data science, ingegneria del software e requisiti provenienti direttamente dal dominio investigativo. Tale integrazione riflette pienamente la visione espressa nella proposta progettuale, secondo cui l'efficacia di strumenti come PENTION-M dipende dalla capacità di tradurre esigenze operative complesse in artefatti ingegneristici robusti e scientificamente fondati.

L'adozione del paradigma DSR consente di strutturare la tesi non solo come un lavoro di implementazione tecnica, ma come un processo di ricerca che parte dall'identificazione del problema, passa attraverso la definizione degli obiettivi e la costruzione di una soluzione, e si conclude con una valutazione integrata nel ciclo stesso di sviluppo. Nel Capitolo 3 verrà presentata in dettaglio l'applicazione concreta del Design Science Research al progetto PENTION-M, includendo il ciclo iterativo, il ruolo degli stakeholder e l'impatto dei requisiti sul design finale del sistema.

1.5 Struttura della tesi

La presente tesi è articolata in sette capitoli, ciascuno dei quali affronta un aspetto specifico del percorso di progettazione, sviluppo e valutazione del sistema PENTION-M. Di seguito si fornisce una panoramica della struttura complessiva dell'elaborato.

- **Capitolo 1 – Introduzione:** introduce il contesto operativo e

scientifico del progetto, chiarisce il ruolo complementare dei sistemi PENTION-S e PENTION-M, definisce gli obiettivi della tesi e presenta la metodologia adottata.

- **Capitolo 2 – Background, Stato dell’Arte e Fondamenti:** offre una rassegna dei concetti teorici e tecnologici necessari per comprendere il sistema sviluppato, includendo una panoramica sulle NPS, sugli spettri EI, sulle principali banche dati utilizzate, sui modelli di dispersione, sulle metodologie PIML, sulle pratiche MLOps e sull’architettura originale di PENTION-S.
- **Capitolo 3 – Metodologia Design Science Research:** descrive l’approccio metodologico adottato, illustra il processo di *Requirements Engineering*, presenta il Data Flow Model delle iterazioni progettuali e documenta il ruolo degli stakeholder nel ciclo di sviluppo.
- **Capitolo 4 – Architettura e Realizzazione di PENTION-M:** costituisce il nucleo tecnico della tesi, mostrando in dettaglio i moduli software, i modelli fisici, i modelli PIML, la pipeline MLOps, il classificatore di sostanze, il sistema di logging forense e l’interfaccia operativa.
- **Capitolo 5 – Validazione e Discussione dei Risultati:** presenta la valutazione dell’artefatto secondo il paradigma DSR, analizza il contributo degli stakeholder, valuta prestazioni e robustezza dei modelli, e include un *Experience Report* con le principali lezioni apprese.
- **Capitolo 6 – Limitazioni e Sviluppi Futuri:** discute le attuali limitazioni tecniche e operative del sistema e suggerisce possibili direzioni di miglioramento, tra cui la conduzione di un field study e l’integrazione con hardware reale.
- **Capitolo 7 – Conclusioni:** sintetizza i contributi principali del lavoro, evidenzia l’impatto scientifico e operativo del sistema proposto e

1. INTRODUZIONE

riflette sul potenziale di PENTION-M come strumento innovativo per il supporto investigativo.

Questa struttura riflette la progressione logica del lavoro svolto, permettendo al lettore di seguire in modo chiaro il percorso che va dall'analisi del problema alla progettazione dell'artefatto, fino alla sua valutazione e contestualizzazione nei possibili scenari futuri.

CHAPTER 2

BACKGROUND, STATO DELL'ARTE E FONDAMENTI

Questo capitolo fornisce il contesto teorico e tecnico necessario a inquadrare il lavoro presentato nella tesi. In particolare, vengono introdotti il dominio applicativo delle *New Psychoactive Substances* (NPS), le tecniche analitiche basate su spettrometria di massa a ionizzazione elettronica (EI), le principali fonti di dati spettrali utilizzate in ambito forense, nonché i modelli fisici e metodologici alla base del sistema PENTION-M. Il capitolo si conclude con una panoramica sullo stato dell'arte relativo al *Physics-Informed Machine Learning* e al ruolo dell'MLOps in sistemi cyber-fisici e contesti forensi.

2.1 New Psychoactive Substances (NPS)

Le *New Psychoactive Substances* (NPS) rappresentano una classe eterogenea di composti chimici progettati per imitare gli effetti di sostanze stupefacenti tradizionali, eludendo al contempo i controlli normativi e le liste delle sostanze proibite. Secondo le definizioni fornite dagli organismi internazionali di riferimento, quali EMCDDA ed UNODC, una NPS è una

sostanza non controllata o recentemente controllata che può rappresentare un rischio per la salute pubblica [1, 2].

Dal punto di vista operativo, le NPS pongono sfide significative alle forze dell'ordine (LEAs) e ai laboratori forensi:

- elevata variabilità strutturale e molecolare;
- rapida introduzione sul mercato di nuove varianti;
- somiglianza spettrale tra composti appartenenti alla stessa classe chimica;
- necessità di identificazione rapida in contesti non controllati.

Queste caratteristiche rendono particolarmente complessa l'identificazione affidabile delle NPS in scenari operativi dinamici, come controlli su strada, ispezioni portuali o interventi in aree urbane densamente popolate.

2.2 Spettrometria di Massa a Ionizzazione Elettronica

La spettrometria di massa a ionizzazione elettronica (Electron Ionization, EI) è una delle tecniche analitiche più consolidate in ambito forense per l'identificazione di sostanze chimiche. Nel processo EI, le molecole vengono ionizzate mediante impatto elettronico ad alta energia (tipicamente 70 eV), generando una serie di frammenti caratteristici che producono uno spettro di massa discreto [3].

Uno spettro EI può essere rappresentato come una funzione discreta:

$$S = \{(m/z_i, I_i)\}_{i=1}^N$$

dove m/z_i indica il rapporto massa/carica e I_i l'intensità relativa del frammento.

Dal punto di vista strumentale, uno spettrometro di massa è composto da tre elementi fondamentali: una sorgente di ionizzazione, un analizzatore di massa e un rivelatore. Nel caso dell'ionizzazione elettronica, le molecole vengono bombardate con elettroni ad alta energia, producendo ioni molecolari e frammenti caratteristici che vengono successivamente separati in base al rapporto massa/carica.

Il risultato dell'analisi è uno spettro di massa che può essere interpretato come una vera e propria impronta chimica della sostanza analizzata. Tale impronta risulta particolarmente utile in ambito forense, poiché consente il confronto diretto con librerie di riferimento e l'identificazione automatica tramite tecniche di matching spettrale o modelli di apprendimento automatico.

I principali vantaggi dell'EI in ambito NPS includono:

- elevata riproducibilità degli spettri;
- compatibilità con ampie librerie di riferimento;
- robustezza rispetto a condizioni operative variabili.

Tuttavia, la frammentazione intensa introdotta dall'EI può generare spettri molto simili tra composti strutturalmente affini, rendendo necessarie tecniche avanzate di analisi e classificazione automatica.

2.3 Dataset e Banche Dati per la Caratterizzazione delle NPS

L'efficacia di un sistema di classificazione basato su spettrometria di massa dipende in larga misura dalla qualità, dalla copertura e dalla coerenza dei dataset utilizzati per l'addestramento dei modelli.

Nel contesto delle NPS, non esiste una singola banca dati esaustiva: i dati disponibili sono distribuiti su più fonti, spesso eterogenee per formato, qualità e convenzioni di naming. Questa frammentazione rende necessaria una fase esplicita di integrazione e normalizzazione dei dataset.

2.3.1 Panoramica delle Fonti di Dati EI

Le principali fonti di dati EI utilizzate in questo lavoro includono:

- librerie open access (es. SWGDRUG, MoNA);
- database accademici e istituzionali (es. SDBS);
- dataset rilasciati come supplementi a pubblicazioni scientifiche;
- archivi forensi ad accesso regolamentato (es. ENFSI).

L'uso combinato di tali fonti consente di ottenere una copertura ampia delle classi NPS, a fronte però di una maggiore complessità nella fase di preprocessing.

2.3.2 SWGDRUG

La libreria SWGDRUG (*Scientific Working Group for the Analysis of Seized Drugs*) rappresenta uno degli standard de facto per la spettrometria di massa forense. Essa fornisce spettri EI di elevata qualità, generalmente accompagnati da metadati affidabili e coerenti [4].

I principali limiti di SWGDRUG riguardano:

- la copertura incompleta delle NPS più recenti;
- la presenza di varianti nominali per lo stesso composto.

2.3.3 MoNA – MassBank of North America

MoNA è una piattaforma open access che aggrega spettri di massa provenienti da numerose fonti [5]. Pur offrendo un'elevata quantità di dati, MoNA presenta una maggiore eterogeneità nella qualità degli spettri e nella completezza dei metadati, rendendo necessaria una selezione mirata dei record EI.

2.3.4 SDBS

Il database SDBS (*Spectral Database for Organic Compounds*) fornisce spettri di riferimento per numerosi composti organici [6]. Nel contesto di questa tesi, SDBS è stato utilizzato per il recupero mirato di spettri EI relativi a specifiche sostanze NPS, in particolare nei casi di assenza di dati in altre librerie.

2.3.5 Problemi di Merging e Normalizzazione

L'integrazione di più fonti EI richiede la risoluzione di diversi problemi:

- duplicazione di composti con naming differente;
- differenze nella risoluzione m/z ;
- normalizzazione delle intensità;
- gestione di spettri incompleti o rumorosi.

Nel sistema PENTION-M, gli spettri EI sono stati vettorizzati su un dominio discreto $m/z \in [1, 600]$, con normalizzazione delle intensità e deduplicazione basata su similarità semantica dei nomi chimici e, ove disponibile, su identificatori strutturali.

2.3.6 Dataset Finale: PENTION_EI_Complete

Il risultato del processo di integrazione è il dataset `PENTION_EI_Complete`, che rappresenta una base spettrale unificata per l'addestramento del classificatore NPS. Il dataset copre un ampio insieme di classi chimiche rilevanti dal punto di vista forense ed è progettato per supportare modelli di classificazione robusti e generalizzabili.

Le sostanze nel dataset sono associate a una delle principali classi chimiche NPS considerate nel lavoro, codificate come etichette discrete utilizzate per l'addestramento supervisionato del classificatore.

In particolare, le classi incluse nel dataset sono:

2. BACKGROUND, STATO DELL'ARTE E FONDAMENTI

- **0:** Cannabinoid analogues;
- **1:** Cathinone analogues;
- **2:** Phenethylamine analogues;
- **3:** Piperazine analogues;
- **4:** Tryptamine analogues;
- **5:** Fentanyl analogues;
- **6:** Other compounds.

La distribuzione delle classi nel dataset risulta sbilanciata, in particolare a favore della classe *Other compounds*, rendendo necessaria l'adozione di tecniche di bilanciamento durante l'addestramento.

Classe chimica	Numero di campioni
Cathinone analogues	620
Cannabinoid analogues	300
Phenethylamine analogues	402
Piperazine analogues	111
Tryptamine analogues	159
Fentanyl analogues	525
Other compounds	1225

Table 2.1: Distribuzione delle classi chimiche nel dataset PENTION_EI_Complete.

Per chiarire la struttura del dataset finale, la Tabella 2.2 riporta un estratto rappresentativo della codifica vettoriale degli spettri EI.

2. BACKGROUND, STATO DELL'ARTE E FONDAMENTI

Sostanza	m/z	41	43	55	57	69	77	91	105	119	133	147	161	Classe
1-(2-Chlorophenyl)piperazine	0.4	2.7	1.2	0.3	0.4	10.9	2.8	0.4	1.4	0.2	0.0	0.0	3	
1-(2-Methoxyphenyl)piperazine	15.0	46.0	25.0	10.0	8.0	135.1	50.0	8.0	1.0	5.0	4.0	0.0	3	
1-(2-Cyclopropylethyl)-1H-indole-3-carbonitrile	6.0	30.0	34.0	2.0	6.0	116.0	12.0	9.0	3.0	39.0	24.0	116.0	6	

Table 2.2: Esempio di rappresentazione vettoriale degli spettri EI nel dataset PENTION_EI_Complete.

2.4 Simulazione della Dispersione Chimica in Ambienti Urbani

La modellazione della dispersione di sostanze chimiche in atmosfera è un problema classico della fisica ambientale. In contesti urbani, tale problema è ulteriormente complicato dalla presenza di edifici, dalla variabilità meteorologica e dalla complessità geometrica dello spazio.

I modelli gaussiani di dispersione, in particolare i modelli *Gaussian Puff* e *Gaussian Plume*, rappresentano una soluzione consolidata per la simulazione di rilasci puntuali [7]. Nel lavoro presentato, tali modelli sono utilizzati come base fisica per la generazione di mappe di concentrazione coerenti, successivamente corrette mediante tecniche di apprendimento automatico informate dalla fisica.

2.5 Physics-Informed Machine Learning

Il *Physics-Informed Machine Learning* (PIML) rappresenta un paradigma che integra conoscenza fisica nei modelli di apprendimento automatico al fine di migliorarne robustezza, interpretabilità e capacità di generalizzazione [8, 9].

Una sistematizzazione completa del paradigma PIML è fornita dalla survey di [10], che rappresenta uno dei riferimenti più ampi e recenti sul tema. Gli autori propongono una tassonomia unificata distinguendo tra approcci *physics-for-machine-learning* e *machine-learning-for-physics*, e classificano le modalità di integrazione della conoscenza fisica in tre categorie principali:

2. BACKGROUND, STATO DELL'ARTE E FONDAMENTI

livello dei dati, livello delle feature e livello della funzione di perdita. La survey introduce inoltre una terminologia condivisa per concetti chiave quali *inductive bias*, *prior physical knowledge* e vincoli fisici *soft* o *hard*, fornendo il quadro concettuale di riferimento utilizzato in questa tesi per l'inquadramento metodologico del PIML.

Nel PIML, la conoscenza fisica può essere incorporata a diversi livelli:

- livello dei dati (dataset generati da modelli fisici);
- livello delle feature (variabili fisicamente significative);
- livello della funzione di perdita (vincoli fisici).

La letteratura recente mostra come il PIML sia particolarmente efficace nei domini governati da equazioni differenziali parziali e caratterizzati da dati scarsi o rumorosi. In particolare, Kashinath et al. analizzano l'impiego del PIML in contesti atmosferici e climatici, evidenziando come l'integrazione di vincoli fisici migliori stabilità e generalizzazione dei modelli in presenza di fenomeni complessi [11]. Studi successivi hanno approfondito l'utilizzo delle *Physics-Informed Neural Networks* (PINNs) in fluidodinamica, mostrando come tali approcci siano adatti a problemi di trasporto, diffusione e dispersione in condizioni di osservabilità limitata [12].

Tali approcci sono stati inoltre applicati a sistemi fisici complessi in ambito geofisico ed energetico, dimostrando la capacità del PIML di sostituire o affiancare simulazioni numeriche tradizionali ad elevato costo computazionale [13].

Nel contesto di PENTION-M, il PIML è utilizzato per correggere la dispersione gaussiana e per migliorare la localizzazione della sorgente, garantendo coerenza con i principi fisici del fenomeno simulato.

In particolare, l'integrazione della conoscenza fisica avviene a più livelli della pipeline, includendo la generazione dei dati simulati, l'ingegnerizzazione delle feature fisiche e l'introduzione di vincoli nella funzione di perdita dei modelli di apprendimento automatico. Questa scelta consente di mantenere

la coerenza fisica del sistema pur beneficiando della flessibilità dei modelli data-driven.

Negli ultimi anni, l'impiego dell'intelligenza artificiale nel dominio delle NPS si è esteso anche a scenari di identificazione in assenza di spettri di riferimento completi. Approcci basati su modelli generativi e predittivi sono stati proposti per stimare spettri di massa a partire dalla struttura molecolare o per suggerire candidati plausibili quando un composto non è presente nelle librerie esistenti.

Sebbene tali metodologie risultino promettenti in ambito di analisi offline o di supporto alla ricerca chimica, il loro utilizzo in contesti operativi sul campo rimane limitato a causa dei requisiti di affidabilità, spiegabilità e tracciabilità richiesti dalle applicazioni forensi. In PENTION-M, l'uso dell'AI è pertanto orientato a supportare il processo decisionale attraverso modelli fisicamente informati e pipeline controllate, piuttosto che a sostituire le procedure di identificazione forense consolidate.

2.6 MLOps in Sistemi Cyber-Fisici e Contesti Forensi

L'adozione di modelli di Machine Learning in sistemi operativi richiede pipeline MLOps in grado di gestire versionamento, monitoraggio, drift dei dati e auditabilità [14, 15].

In contesti forensi e investigativi, tali requisiti sono ulteriormente rafforzati dalla necessità di:

- tracciabilità end-to-end delle decisioni;
- riproducibilità delle inferenze;
- garanzia di integrità e non ripudio dei risultati.

Il sistema PENTION-M integra tali principi mediante una pipeline MLOps containerizzata e un meccanismo di logging forense basato su firme

digitali e bundle verificabili.

2.7 PENTION-S: Architettura di Riferimento

PENTION-S rappresenta la prima iterazione del progetto PENTION, focalizzata su un'architettura statica di analisi e classificazione delle NPS. Pur fornendo una base solida, PENTION-S presenta limiti intrinseci in termini di mobilità, adattabilità e integrazione operativa.

Questi limiti costituiscono la motivazione principale per la progettazione di PENTION-M, che estende il sistema verso un paradigma mobile, fisicamente informato e forense-ready, come discusso nei capitoli successivi.

CHAPTER 3

METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

Questo capitolo descrive la metodologia adottata per la progettazione e lo sviluppo di PENTION-M. In linea con la natura *problem-driven* del contesto forense-operativo, la tesi è impostata secondo un approccio di *Design Science Research* (DSR), in cui la produzione dell'artefatto (PENTION-M) e la sua valutazione sono integrate lungo l'intero ciclo di sviluppo (*validation by construction*). Il capitolo dettaglia: (i) la motivazione della scelta metodologica; (ii) le fasi del processo DSR; (iii) la loro concretizzazione nel progetto PENTION-M; (iv) la campagna di *Requirements Engineering* (RE) condotta con stakeholder del progetto; (v) le iterazioni principali dell'artefatto e il loro legame con i requisiti; (vi) un *Data Flow Model* del processo

3.1 Perché adottare il Design Science

Il problema affrontato in questa tesi presenta caratteristiche che rendono poco adatti approcci puramente sperimentali o esclusivamente ingegneristici. Da un lato, PENTION-M deve rispondere a vincoli operativi reali (tempi,

robustezza, semplicità d'uso, interoperabilità tra enti, auditabilità e catena di custodia). Dall'altro, la soluzione richiede l'integrazione di componenti eterogenei (simulazione fisica, modelli PIML, pipeline MLOps e meccanismi di logging forense) che devono coesistere in un unico sistema coerente.

Il DSR è un paradigma di ricerca applicata che mira a generare conoscenza attraverso la progettazione e la valutazione di un artefatto in grado di risolvere un problema rilevante. In questo lavoro, l'artefatto non è un singolo modello di Machine Learning, ma un prototipo cyber-fisico mobile che implementa un flusso end-to-end: acquisizione di segnali, simulazione fisica, correzione PIML, localizzazione, classificazione, monitoraggio e produzione di evidenze verificabili.

Infine, l'adozione del DSR consente di strutturare in modo rigoroso la collaborazione con stakeholder (LEAs, partner industriali, coordinamento di progetto e supervisor accademici), formalizzando una campagna di RE e rendendo esplicito come i requisiti abbiano guidato le decisioni architetturali e algoritmiche.

3.2 Fasi del Design Science Research

Il processo DSR adottato in questa tesi è organizzato in sei fasi, presentate di seguito in forma generica e successivamente istanziate sul caso PENTION-M:

1. **Identificazione del problema e motivazione** (*Problem Identification*): definizione del problema e dei vincoli del dominio, con evidenza della rilevanza pratica.
2. **Definizione degli obiettivi della soluzione** (*Objectives of a Solution*): traduzione del problema in obiettivi misurabili e requisiti di sistema.
3. **Progettazione e sviluppo** (*Design & Development*): progettazione e implementazione dell'artefatto secondo i requisiti.

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

4. **Dimostrazione** (*Demonstration*): utilizzo dell'artefatto in scenari rappresentativi per mostrare che gli obiettivi possono essere soddisfatti.
5. **Valutazione** (*Evaluation*): raccolta evidenze (tecniche e qualitative) per verificare quanto l'artefatto soddisfi requisiti e obiettivi.
6. **Comunicazione** (*Communication*): documentazione e presentazione dei risultati, incluse limitazioni e sviluppi futuri.

In PENTION-M la valutazione non è confinata a un esperimento finale isolato: ogni iterazione dell'artefatto ha incluso momenti di revisione dei requisiti, feedback stakeholder e miglioramenti incrementali. Questo approccio è coerente con una validazione *by construction*, in cui la qualità del sistema emerge dalla convergenza progressiva tra esigenze del dominio e scelte progettuali.

3.3 Applicazione del DSR al progetto PENTION-M

3.3.1 Identificazione del problema

Il problema di partenza deriva dal dominio di contrasto a laboratori clandestini e traffico di sostanze sintetiche/NPS in cui:

- le operazioni sul campo sono spesso *reattive* e rallentate dai tempi di analisi;
- la complessità dell'ambiente (urbano, logistico, veicolare) rende difficile interpretare segnali e contesto (es. vento, contaminazioni, residui);
- gli strumenti correnti rappresentano un riferimento operativo per usabilità, ma non coprono scenari di campionamento su larga scala (es. container, aree urbane estese);
- la componente forense impone requisiti di tracciabilità e riproducibilità dei risultati.

Inoltre, PENTION-S (baseline di progetto) presenta limiti intrinseci di mobilità, adattabilità e integrazione operativa, motivando l'evoluzione verso PENTION-M come prototipo mobile end-to-end.

3.3.2 Analisi preliminare del sistema PENTION-S

Nel corso delle fasi iniziali del progetto è stato analizzato il sistema PENTION-S, sviluppato per scenari statici e installazioni fisse in infrastrutture critiche. Tale analisi non aveva lo scopo di estendere o aggiornare direttamente l'artefatto esistente, poiché PENTION-S e PENTION-M sono stati concepiti nel progetto come due sistemi autonomi e complementari, destinati a scenari operativi differenti.

Il lavoro svolto su PENTION-S non rappresenta quindi una fase precedente dello stesso artefatto, ma una base conoscitiva iniziale utile a comprendere modelli, scelte progettuali e limiti operativi tipici dei sistemi statici. Queste informazioni sono state utilizzate come input metodologico per l'identificazione dei requisiti e per orientare le scelte architetture di PENTION-M, che è stato sviluppato attraverso un processo di design iterativo dedicato esclusivamente alla mobilità e agli scenari dinamici di pattugliamento urbano.

3.3.3 Obiettivi della soluzione

Gli obiettivi della soluzione sono stati definiti come una combinazione di requisiti operativi e obiettivi tecnico-scientifici:

- **Portabilità e scenario “mobile lab”:** supporto a un laboratorio mobile su van, con possibilità di utilizzo ibrido (sensore handheld + unità nel van).
- **Rilevamento affidabile e controllabile:** minimizzazione dei falsi positivi e gestione di soglie operative realistiche.

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

- **Supporto decisionale AI:** l'AI deve agire come *decision support* e non sostituire la decisione umana.
- **Spiegabilità e auditabilità:** tracciamento dei parametri rilevanti e riproducibilità delle inferenze.
- **Gestione di dati ed evidenze:** esportazione in formati standard, logging robusto e supporto alla catena di custodia (firma digitale, timestamp, integrità).
- **Coerenza fisica della pipeline:** integrazione di conoscenza fisica (simulazione e vincoli PIML) per robustezza e plausibilità dei risultati.
- **Robustezza e aggiornabilità del classificatore NPS:** costruzione e validazione di un dataset EI consolidato e di una pipeline di addestramento ripetibile, in grado di supportare l'evoluzione delle sostanze emergenti.

3.3.4 Progettazione e sviluppo

La progettazione e sviluppo dell'artefatto ha portato a un'architettura a microservizi containerizzati (descritta nel dettaglio nel Capitolo 4), organizzata in livelli funzionali che implementano una pipeline end-to-end. Le scelte progettuali principali includono:

- separazione delle responsabilità tra servizi (ingestion, simulazione fisica, modelli PIML, classificazione, monitoring, logging forense);
- integrazione di vincoli fisici e maschere geometriche in fase di learning (coerenza fisica e plausibilità in ambiente urbano);
- introduzione di componenti MLOps per versionamento dei modelli, raccolta di metriche operative e monitoraggio del comportamento della pipeline, inclusa la predisposizione concettuale alla gestione del drift;
- generazione di evidenze forensi verificabili tramite *forensic bundle* firmato e *tamper-evident*.

3.3.5 Dimostrazione

La dimostrazione dell'artefatto è avvenuta tramite:

- demo incrementalmente eseguite su scenari simulati rappresentativi (patrolling → detection → pipeline → export);
- revisione con supervisor accademici e discussione delle scelte metodologiche e architetturali;
- confronto con stakeholder di progetto per verificare aderenza a esigenze operative e vincoli forensi.

3.3.6 Valutazione

La valutazione è stata integrata nelle iterazioni come:

- valutazione qualitativa tramite feedback stakeholder sui requisiti (usabilità, output, interpretabilità, workflow operativo);
- valutazione tecnica tramite metriche (latenza end-to-end, coerenza fisica, stabilità della localizzazione, calibrazione/confidenza, robustezza del logging forense).

La descrizione completa della valutazione e dei risultati sperimentali è presentata nel Capitolo 5.

3.3.7 Comunicazione

La comunicazione dei risultati è realizzata attraverso:

- la presente tesi, che documenta il processo DSR, la RE e la progettazione dell'artefatto;
- la produzione di documentazione tecnica e log di sviluppo (tracciabilità delle iterazioni, configurazioni e decisioni);
- la preparazione di materiale per demo e workshop con stakeholder.

3.4 Requirements Engineering

La campagna di Requirements Engineering è parte integrante del ciclo DSR: ha permesso di formalizzare esigenze operative e vincoli di contesto, e di convertirli in requisiti verificabili che hanno guidato l'evoluzione di PENTION-M. La RE è stata condotta tra ottobre e novembre 2025 e si è basata su questionari preliminari e un workshop strutturato.

3.4.1 Stakeholder coinvolti

Gli stakeholder coinvolti nella RE e nelle iterazioni includono:

- **LEAs olandesi / End users:** RIEC Limburg (partecipanti al workshop e compilatori dei questionari), con ruoli operativi legati a investigazioni e interventi sul territorio.
- **Consorzio e partner di progetto:** coordinamento e partner industriali (es. MION) e advisory board (es. Guardia Civil) che contribuiscono a requisiti di fattibilità, integrazione e roadmap.
- **Supervisor accademici:** revisione metodologica (DSR), scelte di ingegneria del software e qualità della documentazione.

3.4.2 Strumenti e protocollo di elicitazione

La RE è stata realizzata tramite tre canali complementari:

- **Questionari preliminari:** due questionari compilati dalle LEAs olandesi nelle date del 6 e 13 ottobre 2025, focalizzati su *Operational Challenges* e *Substances & Precursors*.
- **Workshop di elicitazione requisiti:** sessione tenuta il 4 novembre 2025 con brainstorming guidato e raccolta feedback, basata su una presentazione strutturata (*one question per slide*) che copriva nove macro-temi: sfide operative, portabilità, accuratezza di detection,

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

AI assistance, explainability, sostanze/precursori, contesto operativo, gestione dati/evidenze, interazione utente e feedback.

- **Interazioni iterative:** scambi informali e revisioni incrementali con supervisor e partner per chiarire priorità e vincoli (es. requisiti forensi e compliance).

3.4.3 Classificazione dei requisiti

Per facilitare la tracciabilità tra esigenze emerse e design dell'artefatto, i requisiti sono stati classificati in quattro categorie:

- **Requisiti operativi** (workflow, scenari, usabilità, output atteso);
- **Requisiti tecnici** (latenza, portabilità software/hardware, modularità, interoperabilità);
- **Requisiti fisici e di modello** (coerenza con dispersione/trasporto, gestione ostacoli urbani, soglie operative);
- **Requisiti legali e forensi** (audit trail, riproducibilità, integrità, non ripudio, chain of custody, GDPR/compliance).

3.4.4 Sintesi dei requisiti emersi

La Tabella 3.1 sintetizza i requisiti principali emersi da questionari e workshop, organizzandoli con un identificativo (R#) e indicando la loro traduzione in funzionalità di sistema. L'elenco è stato pensato per essere usato anche come *traceability matrix* tra RE e capitoli tecnici successivi.

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

Table 3.1: Sintesi consolidata dei requisiti emersi dalla campagna di Requirements Engineering (questionari e workshop LEAs) e loro mapping su PENTION-M.

ID	Requisito	Implicazioni progettuali in PENTION-M
R1	Rilevamento proattivo e rapido sul campo	Pipeline end-to-end real-time con esecuzione automatizzata e interfaccia operativa (patrolling → detection → output).
R2	Facilità d'uso per operatori non specialisti	Interfaccia minimale con output chiaro (Hit / No Hit + confidenza), ispirata agli strumenti attualmente in uso (es. TruNarc, MX908).
R3	Portabilità (mobile lab su van)	Architettura containerizzata e modulare; modello operativo “Ghostbusters van” per supportare interventi mobili sul territorio.
R4	Supporto a configurazioni ibride (handheld + van)	Separazione tra unità di campionamento portatile e unità di analisi installata nel van; supporto a scenari ibridi di ispezione.
R5	Accuratezza di rilevamento controllabile	Introduzione di soglie operative realistiche emerse dal confronto con le LEA (basso FAR, DR elevato) e calibrazione delle confidenze per distinguere segnali operativamente rilevanti da tracce trascurabili.

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

ID	Requisito	Implicazioni progettuali in PENTION-M
R6	Gestione di <i>old positives</i> e contaminazioni	Parametrizzazione del contesto operativo e delle soglie di rilevamento per ridurre l'impatto di residui storici o contaminazioni ambientali.
R7	AI come <i>decision support tool</i>	Utilizzo dell'AI come supporto all'analisi e all'interpretazione, mantenendo la decisione finale in capo all'operatore umano.
R8	Explainability e audit trail completa	Logging dei parametri rilevanti (meteo, configurazione, versione del modello) e tracciabilità end-to-end delle inferenze per supporto investigativo.
R9	Modalità operative differenziate	Supporto a diversi scenari operativi (urbano, hub postali, checkpoint) tramite profili di configurazione adattivi.
R10	Banca dati dinamica per NPS e precursori	Integrazione di una base dati aggiornabile per la gestione di NPS emergenti e precursori, con supporto a identificazione parziale e <i>unknown matching</i> .
R11	Gestione delle evidenze interoperabilità	Esportazione dei risultati in formati standard e interoperabili, compatibili con i sistemi informativi di polizia e dogane.

ID	Requisito	Implicazioni progettuali in PENTION-M
R12	Integrità, non ripudio e chain of custody	Meccanismi di logging forense con firma digitale, timestamp e proprietà <i>tamper-evident</i> a supporto della catena di custodia.

3.5 Iterazioni dell'artefatto e tracciabilità ai requisiti

Lo sviluppo di PENTION-M è avvenuto attraverso un processo iterativo e incrementale, coerente con l'approccio di Design Science Research, in cui l'artefatto è stato progressivamente raffinato sia sul piano modellistico (PIML) sia su quello architetturale (MLOps). Le versioni descritte in questa sezione rappresentano iterazioni concettuali e architetturali dell'artefatto, ciascuna delle quali ha contribuito a definire e validare specifici aspetti della pipeline MLOps simulata per un sistema cyber-fisico mobile.

3.5.1 Versione 1: prototipo abilitante e pipeline simulata

La prima iterazione dell'artefatto ha avuto uno scopo principalmente abilitante: costruire un prototipo funzionante end-to-end in grado di simulare uno scenario operativo mobile e produrre output interpretabili. Questa fase ha consentito di validare la fattibilità complessiva dell'approccio e di creare una base tecnica su cui innestare successivi raffinamenti.

Gli elementi introdotti includono:

- una pipeline simulata end-to-end con esecuzione automatizzata (supporto a R1);

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

- una prima separazione modulare dei componenti, con containerizzazione orientata alla portabilità (supporto a R3);
- una interfaccia utente minimale, focalizzata sulla chiarezza dell'output operativo (supporto a R2).

Questa versione non mirava all'accuratezza fisica o alla validazione forense, ma a stabilire una base coerente per esplorare integrazioni successive senza richiedere una riprogettazione completa del sistema.

3.5.2 Versione 2: integrazione fisica e modelli PIML

La seconda iterazione ha introdotto un cambiamento concettuale rilevante, spostando la pipeline da un comportamento puramente simulativo e data-driven verso un approccio fisicamente informato. Questa evoluzione è stata guidata dalla necessità di garantire coerenza fisica e plausibilità degli output in contesti urbani e operativi.

In particolare, sono stati introdotti:

- un modello di simulazione fisica della dispersione come base di riferimento per la generazione delle mappe di concentrazione;
- modelli di Physics-Informed Machine Learning per la correzione delle mappe e la localizzazione della sorgente;
- vincoli fisici e geometrici integrati nella loss (non negatività, coerenza con la direzione del vento, maschere spaziali).

Questa iterazione ha risposto ai requisiti legati alla gestione di diversi contesti operativi e alla coerenza fisica degli output (in particolare R9), riducendo il rischio di soluzioni numericamente corrette ma fisicamente implausibili. Questa iterazione ha inoltre posto le basi per l'integrazione dei modelli fisicamente informati all'interno di una pipeline MLOps, rendendo esplicita la separazione tra generazione dei dati, inferenza e logging dei risultati.

3.5.3 Versione 3: calibrazione delle confidenze e controllo dell'overconfidence

Durante le iterazioni precedenti è emersa una criticità tipica dei modelli di classificazione in contesti operativi: la tendenza all'overconfidence, potenzialmente dannosa in scenari investigativi. La terza iterazione ha quindi affrontato esplicitamente il problema della calibrazione delle probabilità.

- è stata introdotta una strategia di Temperature Scaling adattivo per migliorare l'affidabilità delle confidenze (supporto a R5);
- sono state definite soglie operative più robuste rispetto a rumore e contaminazioni, contribuendo alla gestione degli *old positives* (supporto a R6);
- l'output del sistema è stato reso più interpretabile per l'operatore umano, rafforzando il ruolo dell'AI come strumento di supporto decisionale (supporto a R2 e R7).

Questa iterazione ha rafforzato il ruolo della pipeline MLOps come strato decisionale operativo, introducendo meccanismi di controllo delle confidenze e di gestione delle soglie che separano l'inferenza del modello dalla decisione finale, mantenuta in capo all'operatore umano.

3.5.4 Versione 4: logging forense e tracciabilità delle evidenze

La quarta iterazione rappresenta l'introduzione esplicita delle componenti MLOps del sistema. Guidata dai requisiti forensi e di auditabilità, questa fase ha esteso la pipeline oltre la sola inferenza, includendo logging strutturato, versioning dei modelli e gestione delle evidenze, elementi centrali in un contesto cyber-fisico investigativo.

Sono stati introdotti:

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

- un meccanismo di logging forense in grado di catturare input, output e parametri rilevanti per ogni esecuzione end-to-end;
- la generazione di un *forensic bundle* contenente metadati, risultati intermedi e finali, e versionamento dei modelli;
- meccanismi di integrità e non ripudio (firma digitale, proprietà *tamper-evident*);
- l'esportazione delle evidenze in formati strutturati e interoperabili (supporto a R8, R11 e R12).

Questa iterazione colloca PENTION-M non solo come sistema di analisi basato su AI, ma come prototipo di architettura MLOps per ambienti investigativi, in cui inferenza, tracciabilità, auditabilità e sicurezza dei risultati sono parte integrante del ciclo di vita del modello.

3.5.5 Iterazione finale: consolidamento dell'architettura PIML e MLOps

L'iterazione finale ha avuto come obiettivo il consolidamento dell'architettura complessiva PIML e MLOps sviluppata nel corso del progetto. In questa fase, l'attenzione si è concentrata sull'allineamento tra modelli, pipeline operativa e requisiti LEA, verificando la coerenza end-to-end del sistema simulato.

In particolare, sono state consolidate:

- la pipeline MLOps simulata, comprensiva di ingestion, validazione, inferenza, logging e gestione delle evidenze;
- il versioning dei modelli e la tracciabilità completa delle esecuzioni;
- l'integrazione tra componenti PIML e interfaccia operativa, garantendo riproducibilità e auditabilità dei risultati.

Questa fase conclude il ciclo DSR presentato in questa tesi, producendo un prototipo coerente di sistema PIML–MLOps per un contesto cyber-fisico mobile simulato. Sebbene il sistema operi in un contesto simulato, l’architettura MLOps implementata è completa dal punto di vista concettuale e funzionale, e riproduce fedelmente il ciclo di vita di un modello in un sistema cyber-fisico mobile reale.

3.6 Data Flow Model del processo DSR

A valle delle iterazioni dell’artefatto descritte nella sezione precedente, risulta utile sintetizzare il flusso complessivo del processo DSR in una rappresentazione unificata, al fine di rendere esplicito il percorso metodologico seguito in questa tesi. A tal fine, è stato introdotto un *Data Flow Model* non solo del sistema PENTION-M, ma anche del processo di Design Science Research adottato. Tale rappresentazione chiarisce come il lavoro di ricerca abbia guidato, in modo strutturato, la progettazione di un’architettura *Physics-Informed Machine Learning* integrata in un contesto *MLOps* per sistemi cyber-fisici simulati.

La Figura 3.1 fornisce una sintesi visuale del processo DSR seguito. Il diagramma evidenzia come i requisiti operativi, forensi e tecnici raccolti nel contesto LEA siano stati progressivamente tradotti in scelte architettureali, componenti PIML e meccanismi MLOps, attraverso iterazioni successive dell’artefatto.

- il ruolo del contesto iniziale e dell’analisi della baseline PENTION-S come input conoscitivo;
- la fase di Requirements Engineering, basata su questionari e workshop con le LEAs, e la produzione di una lista consolidata di requisiti (R1–R12);
- lo sviluppo iterativo dell’artefatto attraverso versioni successive (V1–V4), guidato dal feedback degli stakeholder;

3. METODOLOGIA: DESIGN SCIENCE RESEARCH (DSR)

- la valutazione integrata (*validation by construction*) e il feedback continuo come meccanismi centrali di refinement;
- l'output finale del processo, rappresentato dal prototipo PENTION-M e dalla relativa documentazione.

Data Flow Model del processo DSR per PENTION-M




Figure 3.1: Data Flow Model del processo di Design Science Research adottato per il progetto PENTION-M.

La figura non descrive l'architettura del sistema, che è presentata nel Capitolo 4, ma ha lo scopo di chiarire la relazione tra le fasi metodologiche del DSR e le attività svolte nel corso del progetto.

3.7 Discussione: validazione by construction e collegamento ai capitoli successivi

Il processo descritto in questo capitolo mostra come la validazione di PENTION-M non sia stata concepita come un singolo esperimento finale, ma come un principio metodologico integrato nello sviluppo dell'artefatto. In linea con l'approccio di Design Science Research, ogni iterazione ha tradotto requisiti in scelte progettuali e architetture, producendo evidenze progressive della loro implementazione e coerenza.

Questo approccio di *validation by construction* costituisce il filo conduttore tra la metodologia presentata in questo capitolo, l'architettura del sistema descritta nel Capitolo 4 e le attività di valutazione discusse nel Capitolo 5. In particolare, le scelte architetture illustrate nel capitolo successivo rappresentano la concretizzazione tecnica dei requisiti e delle iterazioni metodologiche qui descritte, mentre il capitolo di valutazione analizzerà le prestazioni e le proprietà del sistema risultante.

La distinzione tra metodologia, architettura e valutazione consente di mantenere una chiara separazione dei ruoli dei capitoli, preservando al contempo la continuità logica del percorso di ricerca.

CHAPTER 4

ARCHITETTURA E REALIZZAZIONE DI PENTION-M

4.1 Introduzione al Capitolo

Il presente capitolo costituisce il nucleo tecnico della tesi e descrive in dettaglio l'architettura e la realizzazione del sistema PENTION-M, l'artefatto sviluppato nell'ambito del processo di *Design Science Research* illustrato nel Capitolo 3.

In coerenza con l'approccio metodologico adottato, l'architettura di PENTION-M non viene presentata come una semplice implementazione software, ma come la concretizzazione tecnica dei requisiti emersi dalla campagna di *Requirements Engineering* e delle iterazioni progettuali descritte nel capitolo precedente. Ogni scelta architettonica, modellistica e infrastrutturale è pertanto riconducibile a specifiche esigenze operative, fisiche e forensi espresse dagli stakeholder del progetto.

Il sistema è concepito come un *cyber-physical system* simulato che riproduce il funzionamento di un laboratorio mobile per il rilevamento e l'analisi di sostanze psicoattive emergenti. Sebbene l'artefatto operi in un

contesto simulato, l'architettura è stata progettata per riflettere fedelmente un possibile deployment reale. A tal fine, il sistema adotta un'architettura a livelli funzionali, pensata per separare in modo esplicito le fasi di acquisizione dei dati, modellazione fisica, inferenza, monitoraggio operativo e produzione di evidenze verificabili.

L'architettura complessiva integra: (i) una pipeline end-to-end per l'acquisizione e l'elaborazione dei dati; (ii) modelli fisici e modelli di *Physics-Informed Machine Learning*; (iii) una pipeline MLOps completa per il controllo del ciclo di vita dei modelli; (iv) meccanismi di logging forense e generazione di evidenze digitali auditabili.

Il capitolo è organizzato come segue. Nella Sezione 4.2 viene presentata la visione architetturale complessiva di PENTION-M, introducendo i principi di design e la scomposizione del sistema in livelli architetturali funzionali. Le sezioni successive approfondiscono il flusso operativo del sistema, i singoli layer fisici e di apprendimento automatico, la pipeline MLOps, il sistema di logging forense e l'interfaccia operativa. Il capitolo si conclude con una discussione delle scelte architetturali e dei principali trade-off, preparando il terreno per la valutazione dell'artefatto nel Capitolo 5.

4.2 Visione architetturale complessiva di PENTION-M

Dal punto di vista funzionale, PENTION-M implementa un flusso operativo end-to-end, la cui realizzazione è supportata da una specifica architettura a layer che riproduce il comportamento di un laboratorio mobile per la detection e l'analisi di sostanze psicoattive emergenti in contesto urbano. Il sistema integra componenti di simulazione fisica, modelli di apprendimento automatico, servizi MLOps e meccanismi di logging forense all'interno di una pipeline coerente, tracciabile e riproducibile.

Dal punto di vista concettuale, PENTION-M è concepito come un *cyber-physical system* simulato, in cui una componente fisica virtuale

4. ARCHITETTURA E REALIZZAZIONE DI PENTION-M

(rappresentazione dell'ambiente urbano, della dispersione chimica e del movimento del veicolo) è strettamente integrata con una componente computazionale responsabile dell'elaborazione dei dati, dell'inferenza e della produzione degli output operativi. Questa integrazione consente di analizzare il comportamento del sistema in scenari realistici mantenendo il controllo sulla *ground truth* e sui parametri ambientali.

L'intero sistema è implementato come insieme di servizi containerizzati, ciascuno responsabile di una specifica funzione della pipeline. La containerizzazione garantisce isolamento delle dipendenze, portabilità del sistema e riproducibilità delle esecuzioni, consentendo di simulare un deployment operativo in cui i vari componenti cooperano come microservizi. Nel contesto della presente tesi, tali servizi sono eseguiti in un ambiente computazionale controllato; tuttavia, l'architettura è progettata per riflettere uno scenario *edge-only* e *offline-capable*, in cui tutte le operazioni di inferenza, monitoraggio e logging avvengono localmente a bordo del laboratorio mobile.

Dal punto di vista funzionale, PENTION-M implementa una pipeline sequenziale che inizia con la generazione e acquisizione dei dati di scenario, prosegue con l'elaborazione fisica e data-driven delle informazioni, e si conclude con la produzione di output operativi e di evidenze forensi verificabili. Ogni fase della pipeline è progettata per produrre metadati espliciti che descrivono lo stato del sistema, i parametri utilizzati e le versioni degli artefatti coinvolti, abilitando una tracciabilità end-to-end del processo decisionale.

La visione architetturale adottata non mira a massimizzare le prestazioni di singoli modelli isolati, ma a garantire coerenza, robustezza e auditabilità dell'intero sistema. In particolare, l'architettura privilegia: (i) la separazione delle responsabilità tra le diverse fasi del flusso operativo; (ii) l'integrazione esplicita di conoscenza fisica nei modelli di apprendimento; (iii) il monitoraggio continuo del comportamento dei modelli in esecuzione; (iv) la produzione nativa di evidenze digitali forensi.

Sulla base di questi principi, l'architettura di PENTION-M è organizzata in un insieme di livelli architetturali funzionali, ciascuno dei quali incapsula una

specifica porzione del flusso operativo. La Sezione 4.3 introduce formalmente tale architettura a layer, descrivendo il ruolo di ciascun livello e la loro interazione all'interno della pipeline end-to-end.

4.3 Architettura a 8 Layer di PENTION-M

L'architettura di PENTION-M è organizzata secondo un modello a **otto livelli architetturali funzionali**, numerati da Layer 0 a Layer 7, che descrive in modo esplicito la progressione del flusso operativo dal contesto fisico simulato fino alla produzione di output operativi e di evidenze forensi verificabili.

L'adozione di un'architettura a layer risponde a tre obiettivi principali: (i) strutturare il sistema come una pipeline end-to-end coerente; (ii) separare responsabilità fisiche, computazionali e operative; (iii) rendere tracciabili e auditabili le trasformazioni dei dati lungo l'intero processo decisionale. Ogni layer incapsula una fase specifica del flusso e comunica con i livelli adiacenti tramite interfacce ben definite, riducendo accoppiamenti impliciti e facilitando l'analisi e l'evoluzione dell'artefatto.

La Figura 4.1 mostra la visione complessiva dell'architettura a 8 layer di PENTION-M, evidenziando la suddivisione in tre macro-aree funzionali: *Data Flow*, *Inference* e *Output*.




Figure 4.1: Architettura a 8 layer di PENTION-M e flusso end-to-end del sistema.

Panoramica dei layer

- **Layer 0 – Edge I/O (Simulato):** rappresenta il punto di ingresso del sistema e simula la generazione dei segnali provenienti dai sensori virtuali, includendo condizioni meteorologiche, segnali di posizione e dati relativi alla sostanza rilasciata.
- **Layer 1 – Data Ingestion:** gestisce la raccolta dei dati simulati, i controlli di validità e la loro normalizzazione in un formato strutturato coerente, che costituisce l'evento di riferimento per la pipeline.
- **Layer 2 – PIML Feature Layer:** trasforma i dati grezzi in feature fisicamente significative, integrando parametri ambientali, vincoli fisici e informazioni di contesto utili ai modelli di inferenza.
- **Layer 3 – Inference Services:** comprende i servizi responsabili della predizione della dispersione, della localizzazione della sorgente e della classificazione della sostanza, combinando modelli fisici e modelli di *Physics-Informed Machine Learning*.
- **Layer 4 – Monitoring & Telemetry:** osserva il comportamento dei modelli in esecuzione, raccogliendo metriche di latenza, stabilità e affidabilità utili al controllo operativo del sistema.
- **Layer 5 – ModelOps & Logging:** gestisce il versionamento degli artefatti, il tracciamento delle configurazioni di esecuzione e la produzione di audit trail forensi.
- **Layer 6 – Interfaccia Utente Operativa:** fornisce all'operatore una rappresentazione sintetica e interpretabile dei risultati, supportando il processo decisionale in tempo reale.
- **Layer 7 – Forensic Export:** consente l'esportazione delle evidenze generate dal sistema sotto forma di pacchetti verificabili, conformi ai requisiti normativi e forensi.

4.4 Flusso operativo end-to-end (vista runtime)

Sebbene l'architettura di PENTION-M sia descritta attraverso una scomposizione a layer funzionali, il comportamento del sistema a runtime può essere compreso più efficacemente adottando una vista trasversale *end-to-end*. Questa sezione descrive il flusso operativo della pipeline durante l'esecuzione, evidenziando la sequenza di trasformazioni che i dati subiscono dall'acquisizione iniziale fino alla produzione delle evidenze forensi esportabili.

Dal punto di vista logico, il sistema implementa un workflow che attraversa più layer architetturali e può essere suddiviso nelle seguenti macro-fasi:

1. **Patrolling e detection:** simulazione del movimento del laboratorio mobile e verifica delle condizioni di attivazione della pipeline;
2. **Ingestion e normalizzazione:** ricezione del payload sensoriale, validazione e costruzione dell'evento unificato;
3. **Modellazione fisica e correzione PIML:** generazione delle mappe di dispersione e loro raffinamento fisicamente informato;
4. **Inferenza e supporto decisionale:** localizzazione della sorgente e classificazione della sostanza;
5. **Monitoring e ModelOps:** raccolta delle metriche runtime e tracciamento delle versioni di modello;
6. **Forensic export:** generazione del bundle forense e del report operativo.

Questa vista runtime consente di separare la logica operativa del sistema dalla sua organizzazione architetturale, chiarendo come i diversi layer cooperino nella realizzazione di un processo decisionale tracciabile e riproducibile. Nei paragrafi successivi, ciascun layer viene analizzato nel dettaglio, esplicitando il proprio contributo a una o più fasi del flusso end-to-end.

4.5 Layer 0 – Edge I/O e simulazione dei sensori

Il Layer 0 rappresenta il punto di ingresso dell'intero sistema PENTION-M ed è responsabile della simulazione dei sensori e della generazione dei dati fisici e chimici che alimentano la pipeline end-to-end. In coerenza con la natura sperimentale dell'artefatto, tutti i dati acquisiti in questo layer sono interamente simulati, pur essendo progettati per riflettere in modo realistico il comportamento di un laboratorio mobile operativo.

Il layer implementa una simulazione integrata di sensori ambientali, di posizione e di rilevamento chimico, generando un evento di acquisizione strutturato che costituisce l'input per i layer successivi. La scelta di concentrare la simulazione dei sensori in un layer dedicato consente di separare nettamente la generazione dei dati dalla loro elaborazione e inferenza, facilitando la tracciabilità e la riproducibilità degli esperimenti.

Sensori simulati

Il sistema simula tre principali categorie di sensori:

- **Sensori meteorologici:** generano parametri ambientali quali velocità e direzione del vento, temperatura, umidità relativa e classe di stabilità atmosferica secondo la classificazione di Pasquill–Gifford. Tali parametri costituiscono una componente fondamentale per la modellazione della dispersione chimica nei layer successivi.
- **Sensori di posizione (GPS):** simulano la posizione del laboratorio mobile all'interno di una bounding box urbana predefinita. Le coordinate geografiche sono generate in modo coerente con lo scenario urbano simulato, consentendo di associare ogni misura a un contesto spaziale realistico.
- **Sensori di sostanza:** simulano la rilevazione di concentrazioni chimiche e la generazione dello spettro di massa a ionizzazione elettronica (EI).

La sostanza da rilevare è selezionata in modo casuale da un dataset reale di spettri di massa di sostanze psicoattive emergenti, al quale viene applicato rumore controllato per simulare incertezze strumentali e condizioni operative realistiche.

La generazione dello spettro EI non si limita a una forma puramente sintetica, ma sfrutta spettri reali come base, garantendo una maggiore aderenza alle caratteristiche chimiche delle sostanze simulate e rendendo più significativo l'addestramento e la valutazione dei modelli di classificazione.

Sensore mobile e punto di campionamento

Nel prototipo PENTION-M non viene simulata una rete di sensori distribuiti. Tutte le misurazioni ambientali e chimiche sono acquisite a bordo del laboratorio mobile simulato.

Di conseguenza, il punto di campionamento coincide in ogni istante con la posizione del veicolo lungo la traiettoria di pattugliamento. Le osservazioni disponibili al sistema assumono quindi la forma di una serie temporale di misure spazialmente correlate, la cui copertura dipende dal percorso effettuato dal veicolo nello scenario urbano.

Questa scelta progettuale riflette uno scenario operativo realistico e influenza direttamente la formulazione dei task di localizzazione e inferenza, che devono operare in condizioni di osservabilità parziale e dinamica.

Generazione dello scenario e casualità controllata

Per ogni simulazione, il Layer 0 genera uno scenario indipendente identificato da un `simulation_id` univoco e da un timestamp. La sostanza rilasciata, i parametri ambientali e la posizione del veicolo sono selezionati in modo pseudo-casuale.

Questo approccio consente di esplorare un ampio spazio di scenari operativi, mantenendo al contempo il controllo sulla *ground truth* e sui

parametri di simulazione, elemento essenziale per la successiva validazione dei modelli fisici e di *Physics-Informed Machine Learning*.

Output del Layer 0

L'output del Layer 0 consiste in un evento strutturato che aggrega tutte le misure simulate dei sensori e i relativi metadati. Tale evento include esclusivamente dati grezzi e informazioni di contesto (timestamp, identificativo della simulazione, configurazione dello scenario), senza effettuare alcuna inferenza o decisione automatica.

L'evento generato viene trasmesso al Layer 1, dove ha inizio la fase di ingestion e validazione dei dati. Questa separazione garantisce che il Layer 0 rimanga limitato alla sola simulazione dell'acquisizione fisica, riflettendo il ruolo dei sensori reali in un sistema operativo e preservando la modularità complessiva dell'architettura di PENTION-M.

4.6 Layer 1 – Data Ingestion e validazione

Il Layer 1 rappresenta il punto di ingresso operativo della pipeline di PENTION-M e svolge la funzione di *orchestratore centrale* del flusso end-to-end. A questo livello, i dati generati dal Layer 0 vengono ricevuti, validati, arricchiti e trasformati in un evento strutturato unificato che costituisce l'unità informativa di riferimento per tutte le fasi successive della pipeline.

Il servizio di ingestion è implementato come microservizio containerizzato ed è progettato per operare in modalità *edge-only* e *offline-capable*, riflettendo uno scenario operativo reale in cui l'intero processo di acquisizione e analisi avviene localmente a bordo del laboratorio mobile.

4.6.1 Struttura del payload e validazione iniziale

Il Layer 1 riceve in ingresso un payload JSON generato dal sistema di simulazione dei sensori virtuali. Tale payload include informazioni eterogenee relative a: (i) condizioni ambientali e meteorologiche; (ii) posizione geografica del veicolo; (iii) segnali chimici e spettrali associati alla sostanza rilasciata; (iv) identificativi di simulazione e timestamp.

All'atto della ricezione, il payload è sottoposto a una fase di validazione sintattica e semantica. La validazione include:

- verifica della presenza dei campi obbligatori;
- controllo della coerenza temporale (timestamp in formato ISO 8601);
- normalizzazione delle coordinate geografiche rispetto al bounding box di scenario;
- controllo dei range fisici dei parametri ambientali principali.

I dati validati vengono quindi normalizzati in una rappresentazione strutturata che costituisce l'*evento unificato* della pipeline.

4.6.2 Costruzione dell'evento unificato

L'evento unificato aggrega in un singolo oggetto informativo tutte le informazioni rilevanti per l'inferenza, il monitoraggio e la tracciabilità forense. In particolare, l'evento include:

- dati grezzi dei sensori virtuali;
- feature fisiche derivate (ad esempio parametri di dispersione);
- risultati intermedi e finali dei servizi di inferenza;
- metriche di monitoraggio runtime;
- metadati ModelOps relativi a versioni e configurazioni;
- metadati forensi e di compliance.

Questa scelta progettuale consente di mantenere una rappresentazione coerente e auto-consistente dello stato del sistema in ogni istante della pipeline, facilitando sia l'analisi operativa sia le attività di audit e validazione successive.

4.6.3 Orchestrazione dei servizi downstream

Una volta costruito l'evento unificato, il Layer 1 coordina l'invocazione dei servizi di inferenza downstream. In particolare:

- il servizio di simulazione fisica e correzione PIML della dispersione;
- il servizio di localizzazione della sorgente basato su PIML;
- il servizio di classificazione della sostanza tramite modello XGBoost.

Il Layer 1 non implementa logica di inferenza diretta, ma funge da punto di integrazione tra i diversi moduli specializzati, gestendo la propagazione dei risultati all'interno dell'evento unificato.

4.6.4 Integrazione con Monitoring e ModelOps

Contestualmente all'orchestrazione dei servizi di inferenza, il Layer 1 inizializza e aggiorna i meccanismi di monitoraggio runtime. Vengono raccolte metriche relative a:

- latenza dei servizi;
- stabilità delle predizioni;
- indicatori di drift rispetto a baseline di riferimento;
- stato delle versioni di modello attive.

Le informazioni ModelOps associate all'evento includono l'identificativo del modello utilizzato, la versione del dataset di training e l'eventuale attivazione di trigger di retraining. Tali informazioni sono persistite in log strutturati e contribuiscono alla tracciabilità completa del ciclo di vita dei modelli.

4.6.5 Logging forense e produzione delle evidenze

La fase finale del Layer 1 prevede la generazione delle evidenze forensi. L'evento unificato viene serializzato in forma canonica e sottoposto a hashing crittografico tramite algoritmo SHA-256. Il digest risultante viene firmato digitalmente mediante chiavi Ed25519 generate e gestite localmente dal sistema.

Il risultato è un *forensic bundle* contenente:

- l'evento completo;
- l'hash crittografico;
- la firma digitale;
- la chiave pubblica di verifica;
- metadati di compliance e integrità degli artefatti.

I bundle forensi sono immutabili e verificabili ex-post, consentendo la riproduzione e la validazione indipendente del processo decisionale del sistema. In questo modo, il Layer 1 garantisce non solo l'integrità del flusso operativo, ma anche la conformità ai requisiti forensi e normativi definiti in fase di progettazione.

4.7 Layer 2 – Feature fisiche e PIML Feature Layer

Il Layer 2 rappresenta il livello di *feature engineering* fisicamente informato di PENTION-M. A partire dall'evento unificato prodotto dal Layer 1, questo livello ha l'obiettivo di: (i) rendere espliciti i parametri fisici latenti rilevanti per la dispersione e la localizzazione della sorgente; (ii) costruire rappresentazioni numeriche compatibili con i modelli di inferenza impiegati nei layer successivi; (iii) integrare informazione contestuale urbana mediante maschere geometriche.

Nel prototipo implementato, una parte delle feature fisiche viene materializzata già in fase di simulazione (`SensorSim_M.py`) per esigenze di efficienza e semplificazione del flusso end-to-end. Tali feature vengono inserite nel campo `piml_features` dell'evento e propagate ai servizi di inferenza (Layer 3) tramite payload strutturati. Dal punto di vista architetturale, questa scelta non altera il ruolo del Layer 2: le trasformazioni restano concettualmente riconducibili al livello di feature fisiche, anche quando sono materializzate anticipatamente dal simulatore.

4.7.1 Feature meteorologiche e parametri fisici di dispersione

Il sistema include un insieme di parametri ambientali e fisici associati alla dispersione in atmosfera, tra cui condizioni meteorologiche, informazioni sul vento e variabili di stabilità. In particolare, nel simulatore vengono prodotti i parametri: `wind_speed`, `wind_dir` e `stability_class`, che descrivono lo stato atmosferico dello scenario.

Per rendere la direzione del vento utilizzabile in modelli data-driven e PIML, essa viene codificata anche tramite una rappresentazione vettoriale nel piano:

$$\mathbf{v} = \begin{bmatrix} v_x \\ v_y \end{bmatrix} = \begin{bmatrix} \cos(\theta) \\ \sin(\theta) \end{bmatrix} \cdot \|\mathbf{v}\|, \quad (4.1)$$

dove θ rappresenta la direzione del vento e $\|\mathbf{v}\|$ la sua intensità. Questa codifica evita discontinuità angolari e migliora la stabilità dell'apprendimento.

Sulla base della classe di stabilità e delle condizioni di scenario, vengono inoltre calcolati i parametri di dispersione laterale e verticale (σ_y, σ_z), che costituiscono parametri fisici espliciti del modello di dispersione gaussiano. Tali quantità vengono propagate come feature interpretabili e direttamente collegate alla fisica del fenomeno.

La Tabella 4.1 riassume in modo concettuale la struttura del dataset PIML utilizzato per l'addestramento e la validazione dei modelli fisicamente

4. ARCHITETTURA E REALIZZAZIONE DI PENTION-M

informati, evidenziando l'origine e il ruolo di ciascuna categoria di feature all'interno dell'architettura.

Table 4.1: Struttura concettuale del dataset PIML e origine delle feature utilizzate nei modelli di inferenza.

Categoria	Feature	Descrizione	Origine
Meteorologia	<code>wind_speed</code>	Velocità del vento nello scenario simulato	Simulatore (Layer 0)
Meteorologia	<code>wind_dir</code> , $\cos(\theta)$, $\sin(\theta)$	Direzione del vento e codifica vettoriale continua	Layer 2
Stabilità atmosferica	<code>stability_class</code> , <code>stability_index</code>	Classe di stabilità secondo Pasquill–Gifford e indice numerico	Simulatore / Layer 2
Ambiente	<code>RH</code> , <code>humidify</code>	Umidità relativa e flag di umidificazione	Simulatore
Sorgente	<code>source_x</code> , <code>source_y</code> , <code>source_h</code>	Coordinate e altezza della sorgente di emissione	Scenario simulato
Dispersione	<code>emission_rate</code> , (σ_y, σ_z)	Intensità di rilascio e parametri fisici di dispersione	Modello fisico
Spazio	<code>gps_x</code> , <code>gps_y</code>	Coordinate normalizzate del laboratorio mobile	Layer 0
Target	<code>concentration_map</code>	Campo di concentrazione di riferimento (ground truth simulata)	Simulazione fisica
Contesto urbano	<code>building_map</code>	Maschera binaria degli edifici nell'area di interesse	Preprocessing urbano

La distribuzione statistica delle principali variabili fisiche utilizzate nel dataset PIML è mostrata in Figura 4.2, a conferma della coerenza degli intervalli di simulazione con condizioni atmosferiche realistiche.




Figure 4.2: Distribuzione delle principali variabili fisiche utilizzate nel dataset PIML, incluse velocità del vento, indice di stabilità atmosferica e umidità relativa. Gli intervalli mostrati riflettono condizioni atmosferiche realistiche coerenti con lo scenario simulato.

4.7.2 Maschere urbane e contesto geometrico (building map)

Oltre ai parametri atmosferici, PENTION-M integra informazione di contesto urbano attraverso una *building map* binaria che approssima la presenza di edifici nell'area di interesse. La maschera viene generata mediante lo script `binary_map_gen.py`, che interroga OpenStreetMap e costruisce una griglia discretizzata associata a una specifica bounding box.

Nel servizio di correzione PIML, la *building map* viene caricata da file (`.npy`) e utilizzata come canale informativo aggiuntivo insieme alle mappe di concentrazione. Lo schema di input del servizio di correzione prevede infatti: (i) parametri del vento; (ii) una `concentration_map` bidimensionale; (iii) una `building_map` binaria bidimensionale.

Questa scelta consente di incorporare nel flusso data-driven un vincolo

geometrico che approssima l'effetto schermante e canalizzante dell'ambiente urbano, in coerenza con l'approccio *Physics-Informed* adottato.

4.7.3 Feature derivate per la localizzazione della sorgente

Per il task di localizzazione della sorgente, il Layer 2 include un insieme di feature derivate che combinano informazioni sul vento e sulla stabilità atmosferica in variabili più informative. Nel processo di training del modello PIML di localizzazione (`emission_source_piml.ipynb`) vengono utilizzate, tra le altre, feature trigonometrizzate della direzione del vento (seno e coseno), indicatori sintetici di allineamento vento-moto e termini di interazione tra vento, stabilità e variabili ambientali.

Nel contesto architetturale, tali trasformazioni appartengono al Layer 2 poiché rappresentano un'esplicitazione di conoscenza fisica e relazionale che migliora l'apprendimento del modello di localizzazione, implementato nel Layer 3. La corrispondenza tra feature utilizzate in fase di training e feature calcolate a runtime è garantita a livello implementativo nel servizio di localizzazione dedicato.




Figure 4.3: Matrice di correlazione tra le feature fisiche e le feature di interazione utilizzate dal modello PIML per la localizzazione della sorgente. Le correlazioni osservate riflettono relazioni coerenti con i meccanismi fisici di dispersione atmosferica e con la struttura delle feature derivate.

4.8 Layer 3 – Inference Services

Il Layer 3 rappresenta il livello di *inferenza* dell’architettura di PENTION-M ed è responsabile dell’elaborazione dei dati e delle feature prodotte dai layer precedenti al fine di generare output operativi interpretabili. In questo livello sono collocati i servizi che implementano i modelli fisici, data-driven e *Physics-Informed Machine Learning*, ciascuno specializzato in uno specifico task di analisi.

Dal punto di vista architetturale, il Layer 3 è composto da un insieme di microservizi containerizzati, esposti tramite interfacce API ben definite e invocati dal Layer 1 durante l’orchestrazione della pipeline end-to-end. Ogni servizio opera in modo indipendente, consumando un sottoinsieme strutturato

dell'evento unificato e producendo risultati che vengono reintegrati nello stesso evento come output intermedi o finali.

Nel prototipo implementato, il Layer 3 include tre principali classi di servizi:

- simulazione fisica e correzione della dispersione;
- localizzazione della sorgente di emissione;
- classificazione della sostanza tramite spettrometria di massa (EI)

Nota sull'integrazione della classificazione NPS Il servizio di classificazione delle sostanze NPS, sebbene basato su una pipeline modellistica distinta, è pienamente integrato nel Layer 3 di inferenza. L'output del classificatore (classe predetta, confidenza calibrata e candidati alternativi) viene propagato nell'evento unificato e utilizzato sia per il supporto decisionale operativo (Layer 6) sia per la produzione delle evidenze forensi (Layer 7). I dettagli relativi al modello, alla calibrazione delle probabilità e alla valutazione delle prestazioni sono approfonditi nella sezione dedicata alla classificazione NPS.

Questa separazione riflette una precisa scelta progettuale: ogni servizio incapsula una specifica competenza modellistica, riducendo l'accoppiamento tra componenti e facilitando l'evoluzione indipendente dei modelli. Il Layer 3 non gestisce direttamente aspetti di monitoraggio, versionamento o logging forense, che sono delegati ai layer successivi, ma si concentra esclusivamente sull'esecuzione dell'inferenza.

4.8.1 Servizio di classificazione NPS (EI)

Il task di classificazione NPS è implementato come servizio di inferenza dedicato all'interno del Layer 3. Il servizio riceve in input uno spettro EI vettorizzato e restituisce (i) la classe predetta, (ii) le probabilità associate alle classi e (iii) metadati necessari a monitoring e logging forense.

Selezione del modello Durante la fase iniziale di sviluppo è stata condotta un’analisi comparativa tra diversi algoritmi di classificazione supervisionata, con l’obiettivo di selezionare un modello robusto e adatto al dominio spettrale EI. La Figura 4.4 riassume le accuratèzze ottenute sul dataset `PENTION_EI_Complete`.




Figure 4.4: Accuratezza dei modelli valutati nella fase di selezione del classificatore NPS sul dataset `PENTION_EI_Complete`.

In base al confronto, è stato selezionato un modello **XGBoost**, in quanto combina buone prestazioni predittive con stabilità e facilità di integrazione come servizio containerizzato.

Oltre alla scelta dell’algoritmo, è stata posta particolare attenzione all’interpretabilità del classificatore NPS. Al fine di ridurre la dimensionalità del problema e limitare la presenza di feature ridondanti o poco informative, è stata applicata una procedura di *Recursive Feature Elimination* (RFE) basata su Random Forest.

L’analisi delle feature selezionate consente di verificare che il modello fondi le proprie decisioni su contributi spettrali fisicamente e chimicamente significativi, aspetto rilevante in un contesto forense.

4. ARCHITETTURA E REALIZZAZIONE DI PENTION-M




Figure 4.5: Importanza relativa delle feature spettrali selezionate tramite Recursive Feature Elimination (RFE) per il classificatore NPS. Le feature evidenziate risultano coerenti con contributi EI fisicamente e chimicamente interpretabili.

Comportamento del classificatore sul set di test La Figura 4.6 mostra la matrice di confusione del modello XGBoost sul set di test multi-classe, evidenziando anche la capacità di separare la classe negativa *Other compounds* dalle classi NPS.




Figure 4.6: Matrice di confusione del classificatore XGBoost (fase di selezione e integrazione del servizio).

4.8.2 Simulazione fisica della dispersione

Il primo servizio di inferenza del Layer 3 è dedicato alla simulazione fisica della dispersione della sostanza rilasciata nello scenario. Questo servizio implementa un modello di dispersione di tipo *Gaussian Puff*, utilizzato come baseline fisica per descrivere la propagazione spaziale e temporale della concentrazione in atmosfera.

Scelta del modello: plume vs puff Nel contesto di PENTION-M è stato adottato un modello di tipo *Gaussian Puff* in luogo del più tradizionale *Gaussian Plume*. Questa scelta è motivata dalla natura dinamica dello scenario simulato: il punto di campionamento è mobile e le condizioni ambientali possono variare nel tempo. Il paradigma a puff consente di modellare rilasci non stazionari come una sequenza di contributi discreti, risultando più adatto a contesti di pattugliamento urbano.

Forma del contributo gaussiano La concentrazione associata a un singolo puff può essere espressa come:

$$C(x, y, z, t) = \frac{Q}{(2\pi)^{3/2}\sigma_x\sigma_y\sigma_z} \exp\left(-\frac{(x - x_p(t))^2}{2\sigma_x^2} - \frac{(y - y_p(t))^2}{2\sigma_y^2} - \frac{(z - z_p(t))^2}{2\sigma_z^2}\right),$$

e la concentrazione totale come somma dei puff attivi $C_{\text{tot}} = \sum_i C_i(x, y, z, t)$. Nel sistema, tale formulazione fornisce una baseline fisicamente interpretabile per l'integrazione con i modelli PIML successivi.

Il modello riceve in ingresso le feature fisiche prodotte dal Layer 2, tra cui i parametri del vento, la classe di stabilità atmosferica e i coefficienti di dispersione laterale e verticale (σ_y, σ_z). A partire da tali informazioni, il servizio genera una rappresentazione della distribuzione di concentrazione nello spazio, mantenendo una chiara interpretabilità fisica delle grandezze coinvolte.

Nel contesto di PENTION-M, la simulazione fisica non ha l'obiettivo di fornire una previsione atmosferica ad alta fedeltà, ma di costituire un riferimento modellistico coerente e controllabile, utile sia per l'analisi qualitativa dello scenario sia come base per l'integrazione con modelli PIML nei servizi successivi.

Dal punto di vista architettureale, il servizio di dispersione è esposto come microservizio indipendente e viene invocato dal Layer 1 durante la fase di orchestrazione. Il risultato della simulazione viene reintegrato nell'evento unificato sotto forma di mappe di concentrazione strutturate, che possono essere utilizzate sia a scopo operativo sia come input per i modelli di correzione e localizzazione basati su *Physics-Informed Machine Learning*.

La presenza esplicita di un modello fisico nel Layer 3 consente di mantenere un collegamento diretto tra dati osservati, assunzioni fisiche e output di inferenza, costituendo un elemento chiave per la trasparenza e la verificabilità del sistema.

4.8.3 Modello PIML di correzione della dispersione

Il secondo servizio di inferenza del Layer 3 è dedicato alla correzione fisicamente informata dei campi di concentrazione generati dal modello di dispersione gaussiano. Questo servizio implementa un approccio di *Physics-Informed Machine Learning* (PIML) finalizzato a ridurre le discrepanze tra la simulazione fisica semplificata e una rappresentazione più realistica della dispersione in ambiente urbano.

L'obiettivo del modello non è sostituire il modello fisico di base, bensì correggerne sistematicamente gli errori strutturali, mantenendo coerenza con i vincoli fisici noti e con il contesto geometrico dello scenario. In questo senso, il modello PIML opera come un *correction layer* che apprende deviazioni sistematiche dovute a fenomeni non esplicitamente modellati, quali l'interazione con l'ambiente urbano e la complessità dei flussi locali.

Architettura del modello MCxM-PIML Il modello adottato è una rete neurale convoluzionale bidimensionale, implementata nel modulo `MCxM_PIML.py`, progettata per operare su mappe spaziali di concentrazione. L'architettura segue uno schema encoder-decoder di tipo *U-Net-like*, in cui le operazioni convoluzionali consentono di catturare pattern spaziali sia locali sia globali rilevanti per il fenomeno di dispersione.

L'input del modello è multi-canale e comprende: (i) la mappa di concentrazione prodotta dal modello gaussiano; (ii) una *building map* binaria che rappresenta la presenza di edifici nel contesto urbano; (iii) un insieme di parametri fisici scalari associati allo scenario, tra cui velocità e direzione del vento, classe di stabilità atmosferica e umidità relativa. Questa rappresentazione consente al modello di apprendere correzioni spazialmente dipendenti, modulandole in funzione sia del campo di concentrazione sia del contesto geometrico e ambientale.

L'output del modello è una mappa di concentrazione corretta, della stessa dimensionalità dell'input, progettata per approssimare un campo di dispersione più realistico rispetto alla simulazione fisica di base.

Integrazione dei vincoli fisici nella funzione di loss Un elemento centrale dell'approccio PIML adottato è la definizione di una funzione di loss fisicamente informata, implementata nel modulo `loss_function_piml.py`. La funzione di perdita combina una componente di errore predittivo con termini di penalizzazione che riflettono vincoli fisici espliciti.

In particolare, la loss include contributi associati a: (i) accuratezza della previsione rispetto al campo di riferimento; (ii) regolarità spaziale del campo corretto, al fine di evitare discontinuità non fisicamente plausibili; (iii) penalizzazione della presenza di concentrazione all'interno delle aree edificate; (iv) coerenza tra il gradiente spaziale del campo di concentrazione e la direzione del vento dominante. Questo approccio guida l'addestramento verso soluzioni che risultano non solo numericamente accurate, ma anche fisicamente coerenti, riducendo il rischio di overfitting puramente data-driven.

Dataset PIML e pipeline di addestramento Il modello è addestrato su un dataset simulato specificamente progettato per il contesto PIML. I dati vengono generati tramite lo script `simulation_gen.py` e successivamente preprocessati mediante `dataset_preprocessing_piml.py`. Per ciascuna simulazione, il dataset include: (i) parametri ambientali e meteorologici; (ii) mappe di concentrazione generate dal modello fisico; (iii) mappe di riferimento

della dispersione “reale”; (iv) maschere urbane coerenti con la bounding box geografica dello scenario.

La pipeline di training, implementata in `cnn_train_pipeline_piml.py`, gestisce la suddivisione in training e validation set, il caricamento dei dati tramite la classe `CNNDataset` e l’ottimizzazione dei pesi del modello. L’andamento della loss su training e validation è utilizzato per monitorare la stabilità dell’addestramento e verificare l’assenza di fenomeni di overfitting.

Esposizione come servizio di inferenza Una volta addestrato, il modello PIML viene serializzato e caricato dal servizio di inferenza `service_correction_piml.py`, esposto tramite API REST definite in `api_correction_piml.py`. Il servizio riceve in ingresso le mappe di concentrazione e i parametri di scenario prodotti dai layer precedenti e restituisce una mappa corretta che viene integrata nell’evento unificato della pipeline.

Dal punto di vista architetturale, il servizio è stateless e completamente containerizzato, garantendo riproducibilità delle inferenze e integrazione trasparente nel flusso end-to-end. Le informazioni relative alla versione del modello e ai parametri di esecuzione vengono propagate ai layer di Monitoring e ModelOps per finalità di tracciabilità e auditabilità.

Ruolo del modello PIML nel Layer di inferenza Il modello PIML di correzione della dispersione rappresenta un punto di equilibrio tra modellazione fisica e apprendimento automatico. All’interno del Layer 3, esso agisce come ponte tra simulazione fisica e inferenza avanzata, migliorando l’affidabilità delle mappe di concentrazione utilizzate dai successivi moduli di localizzazione della sorgente e di valutazione operativa del rischio.

4.8.4 Modello di localizzazione della sorgente

Il terzo servizio di inferenza del Layer 3 è dedicato alla *localizzazione della sorgente di emissione* della sostanza rilevata, ovvero alla stima delle coordinate

spaziali della sorgente responsabile del campo di concentrazione osservato dai sensori. Questo task rappresenta un passaggio cruciale nella pipeline operativa di PENTION-M, in quanto traduce l'informazione di dispersione in un output direttamente utilizzabile a fini investigativi e decisionali.

Nel prototipo implementato, la localizzazione della sorgente è realizzata mediante un modello di *Physics-Informed Machine Learning* (PIML), progettato per integrare esplicitamente informazione fisica e geometrica nel processo di inferenza, riducendo l'ambiguità tipica degli approcci puramente data-driven.

Feature fisiche utilizzate Il modello di localizzazione opera su un insieme di feature derivate prodotte dal Layer 2, che rendono esplicite le principali grandezze fisiche coinvolte nel fenomeno di dispersione. In particolare, l'input del modello include:

- componenti cartesiane della direzione del vento ($\cos(\theta)$, $\sin(\theta)$), che evitano discontinuità angolari;
- intensità del vento (`wind_speed`);
- indicatori di stabilità atmosferica, derivati dalla classificazione di Pasquill–Gifford;
- coordinate spaziali dei sensori operativi (`gps_x`, `gps_y`);
- serie temporali delle concentrazioni misurate dai sensori;

Questa rappresentazione consente al modello di apprendere relazioni fisicamente plausibili tra la distribuzione spaziale delle misure, le condizioni ambientali e la posizione della sorgente. L'utilizzo esplicito di feature fisiche riduce la dimensionalità latente del problema e migliora la stabilità dell'inferenza in scenari eterogenei.

4. ARCHITETTURA E REALIZZAZIONE DI PENTION-M

Architettura e addestramento del modello PIML Il modello di localizzazione è addestrato offline utilizzando il notebook `emission_source_piml.ipynb`, a partire da dataset simulati coerenti con gli scenari operativi di PENTION-M. L'addestramento sfrutta una normalizzazione consistente delle feature, serializzata nel file `scaler_piml.pkl`, al fine di garantire coerenza tra fase di training e fase di inferenza runtime.

Il modello finale, salvato come `emission_source_model_piml.pkl`, implementa una regressione multivariata che stima direttamente le coordinate spaziali della sorgente. L'approccio PIML consente di limitare soluzioni non fisicamente plausibili, vincolando implicitamente lo spazio delle predizioni alle configurazioni compatibili con la dinamica della dispersione atmosferica.

Stabilità dell'inferenza e output del servizio Dal punto di vista operativo, il modello di localizzazione è esposto come microservizio stateless tramite API REST definite in `api_source_localization_piml.py` e implementate nel servizio `service_source_localization_piml.py`. Il servizio riceve in ingresso i dati strutturati dei sensori e restituisce una stima puntuale della posizione della sorgente, accompagnata da metadati di esecuzione e versioning del modello.

Le metriche di validazione ottenute in fase di test mostrano una buona stabilità del modello, con errori medi dell'ordine di alcune decine di metri, compatibili con la risoluzione spaziale dello scenario simulato. In particolare, i valori di RMSE e MAE confermano la capacità del modello di fornire stime robuste anche in presenza di rumore e di parziale incompletezza delle misure.

All'interno dell'architettura di PENTION-M, l'output del servizio di localizzazione viene reintegrato nell'evento unificato della pipeline e reso disponibile sia per la visualizzazione operativa (Layer 6) sia per la produzione di evidenze forensi verificabili (Layer 7). In questo modo, il modello di localizzazione della sorgente completa il Layer 3 di inferenza, fornendo un collegamento diretto tra modellazione fisica, apprendimento automatico e

supporto decisionale.

4.9 Layer 4 – Monitoring e Telemetry

Il Layer 4 rappresenta il livello di *monitoring operativo e telemetry* di PENTION-M ed è responsabile dell'osservazione continua del comportamento della pipeline durante l'esecuzione. A differenza di approcci MLOps tradizionali orientati esclusivamente a metriche statistiche di accuratezza offline, questo layer è progettato per monitorare *proprietà runtime fisicamente e operativamente rilevanti*, in coerenza con la natura cyber-fisica e forense del sistema.

Il servizio di monitoring è implementato come microservizio containerizzato (`monitoring_service.py`) ed è invocato automaticamente dal Layer 1 al termine di ogni ciclo di inferenza end-to-end. Il layer non interviene direttamente nel processo decisionale, ma fornisce una visione strutturata dello stato del sistema, abilitando controlli di stabilità, affidabilità e auditabilità.

4.9.1 Ruolo del monitoring nel contesto PENTION-M

Nel contesto di PENTION-M, il monitoring assolve a tre funzioni principali:

- **controllo operativo runtime**, monitorando latenza, drift e stabilità delle predizioni durante l'esecuzione;
- **supporto alla pipeline ModelOps**, fornendo segnali quantitativi per la gestione delle versioni e dei retraining;
- **tracciabilità forense**, producendo log strutturati e immutabili utilizzabili per audit e validazione ex-post.

Questa impostazione riflette una precisa scelta progettuale: il monitoring non è trattato come componente accessoria, ma come parte integrante dell'architettura di validazione *by construction* dell'artefatto.

4.9.2 Struttura dell'evento di monitoring

Il Layer 4 riceve in ingresso l'evento unificato prodotto dal Layer 1, che include informazioni sui sensori, sulle feature PIML, sui risultati di inferenza e sui metadati ModelOps. A partire da tale evento, il servizio di monitoring estrae un sottoinsieme coerente di informazioni rilevanti, organizzate in un blocco di telemetry strutturato.

In particolare, per ogni simulazione vengono monitorate:

- la latenza complessiva della pipeline (`latency_ms`);
- la versione del modello attivo (`model_version`);
- indicatori di stabilità fisica e modellistica;
- la confidenza associata alle predizioni;
- un indice sintetico di drift (`drift_score`).

Tali informazioni vengono serializzate in formato JSON Lines all'interno del file `monitoring_log.jsonl`, costituendo una traccia temporale ordinata degli eventi di esecuzione del sistema.

4.9.3 Monitoraggio della latenza

La latenza rappresenta una metrica critica nel contesto operativo di un laboratorio mobile. Il Layer 4 distingue tra:

- latenza end-to-end osservata dal client;
- latenza interna misurata dal sistema durante la pipeline.

La latenza interna è calcolata utilizzando timestamp coerenti propagati lungo il flusso di ingestion e inferenza. Questa misura consente di valutare il carico computazionale dei singoli componenti e di identificare condizioni di stress o degrado prestazionale.

Nel contesto simulato di PENTION-M, latenze dell'ordine di alcuni secondi sono considerate accettabili, in quanto il sistema esegue: (i) simulazioni

fisiche costose; (ii) modelli PIML convoluzionali su mappe bidimensionali; (iii) pipeline di classificazione e logging forense. Il monitoring consente di caratterizzare tali latenze e di contestualizzarle correttamente.

4.9.4 Drift fisicamente informato

Un elemento distintivo del Layer 4 è l'introduzione di un *drift fisicamente informato*, progettato per catturare variazioni anomale nel comportamento del sistema rispetto a una baseline operativa.

Il drift non è calcolato esclusivamente sulle feature di input, ma su un vettore fisico composito che include:

- parametri di dispersione (σ_y, σ_z);
- indicatori di stabilità atmosferica;
- numero di Péclet e grandezze di trasporto;
- velocità e direzione del vento;
- confidenza dei modelli di inferenza.

A partire da questo vettore, il servizio implementa un meccanismo di drift basato sulla distanza di Mahalanobis rispetto a una baseline incrementale, memorizzata nel file `drift_baseline.json`. Durante le prime esecuzioni, la baseline viene costruita progressivamente; una volta stabilizzata, il drift viene normalizzato rispetto alla distribuzione storica.

Il risultato è un valore scalare $\in [0, 1]$ che quantifica la deviazione dello stato corrente del sistema rispetto al comportamento atteso, senza richiedere accesso alla ground truth reale. Questo approccio è particolarmente adatto a contesti fisico-forensi, in cui il concetto di drift deve riflettere anche coerenza fisica e affidabilità operativa.

4.9.5 Stabilità e confidenza delle predizioni

Oltre al drift, il Layer 4 monitora indicatori di stabilità delle predizioni prodotte dai modelli PIML e dal classificatore NPS. In particolare, vengono tracciate:

- la confidenza associata alle predizioni di classificazione;
- la coerenza delle stime di localizzazione della sorgente;
- variazioni improvvise di output a parità di condizioni fisiche.

Queste informazioni consentono di individuare situazioni di overconfidence, instabilità numerica o degrado progressivo delle prestazioni, fornendo segnali utili sia all'operatore umano sia ai meccanismi ModelOps dei layer successivi.

4.9.6 Persistenza e auditabilità dei log

Tutti i dati di monitoring vengono persistiti in forma append-only, senza modifiche retroattive, garantendo l'integrità temporale delle informazioni. Il formato JSON Lines consente analisi batch, visualizzazioni offline e integrazione diretta con le procedure di validazione descritte nel Capitolo 5.

Dal punto di vista architetturale, il Layer 4 costituisce il ponte tra inferenza e ModelOps: le metriche prodotte non influenzano direttamente l'output operativo immediato, ma alimentano i processi di controllo, versioning e logging forense implementati nel Layer 5.

In questo modo, il monitoring non si limita a osservare il sistema, ma contribuisce attivamente alla sua validazione, robustezza e affidabilità complessiva.

4.10 Layer 5 – ModelOps e logging forense

Il Layer 5 rappresenta il livello di *ModelOps e logging forense* di PENTION-M ed è responsabile della gestione del ciclo di vita dei modelli, della

tracciabilità delle configurazioni di esecuzione e della produzione di evidenze digitali verificabili. Questo layer costituisce un elemento chiave dell'artefatto, in quanto traduce le esigenze di auditabilità, riproducibilità e affidabilità emerse in fase di *Requirements Engineering* in meccanismi tecnici espliciti e verificabili.

A differenza di pipeline MLOps orientate esclusivamente all'automazione del retraining o all'ottimizzazione continua delle prestazioni, PENTION-M adotta un approccio *conservativo e forense-aware*: le decisioni operative sono sempre accompagnate da metadati completi, e ogni esecuzione produce un audit trail immutabile. In questo senso, il Layer 5 non è progettato per intervenire dinamicamente sull'inferenza runtime, ma per garantire che ogni risultato prodotto dal sistema sia contestualizzato, verificabile e difendibile ex-post.

4.10.1 Ruolo del ModelOps nel contesto PENTION-M

Nel contesto di PENTION-M, il termine *ModelOps* è inteso in senso esteso e include non solo il versionamento dei modelli, ma l'intera gestione del loro utilizzo operativo. Il Layer 5 assolve in particolare a quattro funzioni principali:

- tracciamento delle versioni dei modelli e delle configurazioni attive;
- associazione esplicita tra modelli, dati di input e output prodotti;
- registrazione degli eventi rilevanti per il ciclo di vita dei modelli;
- produzione di evidenze forensi verificabili e immutabili.

Questo approccio riflette una scelta progettuale deliberata: in un contesto investigativo e forense, la priorità non è l'adattamento automatico dei modelli, bensì la possibilità di ricostruire in modo completo e indipendente il processo decisionale seguito dal sistema in un determinato istante temporale.

4.10.2 Versioning dei modelli e audit trail

Il versionamento dei modelli è gestito tramite un registro persistente (`model_registry.json`) che associa a ciascun modello utilizzato le informazioni rilevanti per la sua identificazione e riproducibilità. Per ogni servizio di inferenza vengono tracciati:

- identificativo e versione del modello;
- tipologia di modello (fisico, PIML, data-driven);
- data di registrazione e di attivazione;
- riferimento alla configurazione di training;

Durante l'esecuzione della pipeline, il Layer 1 propaga nell'evento unificato l'identificativo delle versioni di modello effettivamente utilizzate. Il Layer 5 raccoglie tali informazioni e le persiste come parte dell'audit trail, garantendo che ogni output possa essere ricondotto in modo univoco agli artefatti software che lo hanno generato.

Le operazioni di retraining non avvengono in modo opaco o non supervisionato, ma sono attivate automaticamente in risposta a condizioni operative esplicitamente monitorate dal sistema. In particolare, eventi di drift, instabilità o degrado delle prestazioni possono generare automaticamente un trigger di retraining, gestito e registrato dal sottosistema ModelOps.

Ogni evento di retraining viene tracciato separatamente nel file `modelops_retrain_log.jsonl`, che documenta in modo esplicito: (i) la condizione che ha innescato il retraining; (ii) la versione precedente e quella candidata del modello; (iii) l'esito dell'operazione.

Questa separazione tra rilevazione automatica, esecuzione controllata e tracciamento persistente consente di mantenere un elevato livello di automazione, senza compromettere i requisiti di auditabilità e controllo umano richiesti in un contesto forense.

4.10.3 Logging forense e struttura del bundle

Il cuore del Layer 5 è rappresentato dal sistema di logging forense, implementato nel modulo `forensic_logger.py`. Al termine di ogni esecuzione completa della pipeline, l'evento unificato viene trasformato in un *forensic bundle*, ovvero un pacchetto digitale autosufficiente che rappresenta l'evidenza dell'attività svolta dal sistema.

Il processo di generazione del bundle prevede:

1. serializzazione canonica dell'evento unificato;
2. calcolo dell'hash crittografico tramite algoritmo SHA-256;
3. firma digitale del digest mediante algoritmo Ed25519;
4. inclusione della chiave pubblica necessaria alla verifica.

Il bundle risultante contiene:

- l'evento completo, comprensivo di input, output e metadati;
- l'hash SHA-256 dell'evento serializzato;
- la firma digitale;
- la chiave pubblica associata;
- informazioni di supporto alla verifica e alla compliance.

Ogni bundle è persistito in forma append-only all'interno della directory `logs/forensic/` e identificato da un nome univoco che include timestamp e identificativo di simulazione. Una volta generato, il bundle non viene mai modificato, garantendo l'immutabilità dell'evidenza.

4.10.4 Firma digitale e verifica dell'integrità

La firma digitale Ed25519 consente di verificare in modo indipendente sia l'integrità sia l'autenticità del bundle. Il processo di verifica, implementato nello script `verify_bundle.py`, ricostruisce l'evento in forma canonica,

ricalcola l'hash SHA-256 e verifica la firma mediante la chiave pubblica inclusa nel bundle stesso.

Verifica zero-trust e inclusione dei compliance tag Il processo di verifica adotta un approccio *zero trust*: l'hash non viene considerato affidabile in quanto dichiarato nel bundle, ma viene ricalcolato ex-novo a partire dall'evento serializzato in forma canonica. La firma digitale è quindi verificata utilizzando l'hash ricalcolato e la chiave pubblica inclusa, rendendo immediatamente rilevabile qualsiasi alterazione del contenuto.

I tag di compliance e di audit vengono inseriti nell'evento prima della fase di hashing e firma. In questo modo, tali informazioni diventano parte integrante del contenuto firmato e non possono essere modificate a posteriori senza invalidare l'intera evidenza forense.

Questo meccanismo consente di rilevare qualsiasi alterazione, anche minima, dei dati registrati. Test di manomissione controllata, implementati nello script `tamper_test.py`, mostrano che la modifica di un singolo campo dell'evento (ad esempio una coordinata GPS) invalida immediatamente sia il confronto degli hash sia la verifica della firma digitale. Tali test confermano la robustezza del meccanismo di protezione e la sua idoneità a contesti forensi.

4.10.5 Chain of custody digitale

L'insieme di versioning, logging strutturato, hashing e firma digitale implementato nel Layer 5 realizza una forma di *chain of custody digitale*. Ogni evidenza prodotta dal sistema è:

- temporalmente collocabile;
- riconducibile a una specifica configurazione di modelli;
- verificabile in modo indipendente;
- resistente a manomissioni non autorizzate.

Dal punto di vista architetturale, il Layer 5 separa in modo esplicito le metriche di monitoring operativo (Layer 4) dalle evidenze forensi, evitando commistioni tra osservazione del comportamento del sistema e produzione di prove digitali. Questa separazione rafforza la chiarezza concettuale del sistema e facilita la validazione ex-post delle decisioni prese.

4.10.6 Collegamento con la validazione *by construction*

Il Layer 5 costituisce un elemento fondamentale della validazione *by construction* di PENTION-M. La produzione sistematica di bundle forensi firmati garantisce che ogni iterazione dell'artefatto e ogni esecuzione della pipeline siano documentate in modo completo e verificabile.

In questo senso, il logging forense non rappresenta un'aggiunta a posteriori, ma una componente strutturale dell'architettura. Le proprietà di auditabilità, riproducibilità e tracciabilità non sono valutate tramite un singolo esperimento finale, bensì emergono direttamente dal modo in cui il sistema è stato progettato e implementato. Il Capitolo 5 approfondirà questo aspetto, mostrando come tali meccanismi abbiano supportato la valutazione tecnica e il confronto con gli stakeholder nel corso delle iterazioni del progetto.

4.11 Layer 6 – Interfaccia utente operativa e demo live

Il Layer 6 fornisce il punto di contatto operativo tra l'analista e la pipeline end-to-end di PENTION-M. L'obiettivo dell'interfaccia non è soltanto “mostrare un output”, ma *rendere ispezionabile* l'intero ciclo di rilevazione: movimento del laboratorio mobile, attivazione della pipeline MLOps, visualizzazione delle metriche di monitoring e accesso immediato alle evidenze forensi prodotte dal sistema.

Dal punto di vista implementativo, la UI è esposta come servizio web leggero (`PentionSystem_M/ui_pention_m.py`) che: (i) serve asset statici

(`index.html`, `script.js`, `style.css`); (ii) mantiene uno stato di simulazione lato server (es. *Idle/Running*); (iii) comunica aggiornamenti in tempo reale al browser tramite un canale WebSocket (`/ws`). Questa scelta progettuale consente di ottenere una visualizzazione reattiva senza introdurre dipendenze pesanti, mantenendo coerenza con lo scenario *edge-only* e *offline-capable* del laboratorio mobile.

4.11.1 Componenti visuali e logica di interazione

L'interfaccia è organizzata in due aree principali:

- **Mappa operativa (sinistra):** una mappa interattiva basata su Leaflet, alimentata da OpenStreetMap, su cui viene renderizzato il van e la sua evoluzione spaziale nello scenario urbano. La navigazione del veicolo è vincolata a una rete stradale pre-caricata da cache (`osm_cache/amsterdam_drive.graphml`), ottenendo un comportamento coerente con un pattugliamento urbano realistico.
- **Pannello di controllo e telemetry (destra):** un insieme di card che sintetizzano lo stato della simulazione e i risultati della pipeline (*Simulation info*, *EI Mass Spectrum*, *Last forensic bundle*).

La UI espone tre comandi operativi che riflettono il workflow d'uso:

- **Start simulation:** avvia una simulazione standard in cui il van si muove secondo logica di patrolling; la pipeline MLOps viene attivata quando viene soddisfatta la condizione di detection (cioè quando lo scenario simulato produce un evento coerente con la presenza della sorgente).
- **Reset:** reinizializza lo stato della simulazione e della visualizzazione.
- **Debug: Start near source:** modalità di debug usata per validazioni rapide, in cui il van viene inizializzato in prossimità della sorgente; la pipeline downstream è identica alla modalità standard, ma con tempi di attivazione più rapidi.

Logica di detection e stabilizzazione L'attivazione della pipeline downstream non è continua, ma vincolata a una condizione di detection basata sulla prossimità spaziale del veicolo rispetto all'area di interesse. La detection viene valutata tramite distanza geodetica e costituisce il trigger operativo per l'invocazione della pipeline MLOps.

Per evitare oscillazioni spurie dovute a micro-variazioni della posizione (GPS jitter), è introdotto un meccanismo di isteresi spaziale che stabilizza la condizione di ingresso e uscita dall'area di detection. Questa soluzione migliora la riproducibilità della demo e rende il comportamento del sistema più coerente con uno scenario operativo reale.

4.11.2 Aggiornamento real-time e integrazione con la pipeline

Durante l'esecuzione, il backend invia al client aggiornamenti incrementali tramite WebSocket. Il browser riceve tali messaggi e aggiorna in tempo reale:

- **stato della simulazione** (es. *Idle/Running*) e identificativo (`simulation_id`);
- **model versioning** riportato dalla pipeline (es. `PIML_v8`);
- **metriche di monitoring** prodotte dal Layer 4: drift score, latenza, stability index e confidenza;
- **spettro EI corrente** (card *EI Mass Spectrum*), renderizzato come grafico a barre/linea per supportare un controllo visivo immediato del segnale;
- **riassunto dell'ultimo bundle forense** generato, con campi essenziali per triage operativo (predizione del modello, confidenza, vento, coordinate GPS e hash).

Questa modalità di aggiornamento è progettata per essere *operativamente leggibile*: le metriche non sono presentate come dettagli tecnici isolati, ma come indicatori di stato che consentono all'operatore di valutare rapidamente (i) l'affidabilità della predizione, (ii) l'eventuale presenza di condizioni anomale (drift elevato), e (iii) il costo temporale della pipeline (latenza end-to-end).

4.11.3 Report operativo e collegamento alle evidenze forensi

Un requisito centrale emerso in fase progettuale è la possibilità di passare dalla visualizzazione operativa alla verifica forense senza salti manuali. Per questo motivo la UI include una vista dedicata al *Forensic Detection Report*, accessibile dalla card *Last forensic bundle* tramite il comando *View full report*.

Il report è costruito a partire dai metadati già presenti nel bundle generato dal Layer 7, e organizza in modo leggibile: (i) identificativi di simulazione e timestamp; (ii) output di classificazione (classe e confidenza); (iii) condizioni meteo e parametri di contesto rilevanti; (iv) riferimenti di integrità (hash e identificativo del bundle). In aggiunta, la UI include una funzione di esportazione in PDF (azione *Download PDF*) per produrre rapidamente un artefatto condivisibile e stampabile, senza compromettere la catena di tracciabilità: il PDF rappresenta una vista umana del contenuto, mentre la verifica crittografica resta ancorata al bundle firmato generato dal sistema.

4.11.4 Discussione: ruolo della UI nella validazione by-construction

Nel contesto di PENTION-M, l'interfaccia non è un componente accessorio, ma parte integrante del paradigma di validazione *by construction*. La UI rende espliciti (e quindi discutibili e verificabili) gli elementi chiave del ciclo: la versione di modello effettivamente utilizzata, le metriche runtime prodotte dal monitoring, e l'esistenza di un'evidenza forense immediatamente

ispezionabile. In questo modo, l'operatore (o un auditor) può osservare l'intero flusso *Patrolling* → *Detection* → *Inference* → *Monitoring* → *Forensic bundle*, riducendo il rischio di “black-boxing” operativo e migliorando la riproducibilità complessiva degli esperimenti.

4.12 Layer 7 – Forensic Export e reporting

Il Layer 7 rappresenta il livello di *Forensic Export* di PENTION-M e ha l'obiettivo di trasformare l'esecuzione end-to-end della pipeline in un insieme di **evidenze digitali esportabili**, pensate per due scopi complementari: (i) *preservazione* e *verificabilità* (output machine-readable, orientato ad audit); (ii) *comunicazione operativa* (output human-readable, orientato a consultazione e reporting).

Coerentemente con i requisiti forensi emersi durante la progettazione dell'artefatto, l'export non è trattato come una semplice funzione di “salvataggio risultati”, ma come una fase strutturata di *chain of custody digitale*: l'output deve poter essere archiviato, trasferito e verificato ex-post da terze parti, senza dipendere dall'ambiente di esecuzione originale.

4.12.1 Export in formato JSON: bundle forense verificabile

Il formato primario di esportazione è un **bundle JSON** che incapsula in modo auto-consistente le informazioni necessarie a ricostruire l'esecuzione della pipeline. In particolare, il bundle include: (i) l'*evento unificato* completo (sensori, feature PIML, output di inferenza, metadati); (ii) un digest crittografico calcolato sull'evento in forma canonica (SHA-256); (iii) una firma digitale del digest (Ed25519) e la chiave pubblica per la verifica.

La presenza congiunta di hash e firma consente di verificare due proprietà fondamentali: **integrità** (nessuna modifica al contenuto) e **autenticità** (provenienza dal sistema che detiene la chiave privata). A livello implementativo, la verifica può essere eseguita in modo indipendente tramite

uno script dedicato che: (i) ricalcola l’hash a partire dall’evento serializzato in forma canonica; (ii) confronta l’hash calcolato con quello contenuto nel bundle; (iii) verifica la firma Ed25519 usando la chiave pubblica inclusa nel bundle. Questo meccanismo rende l’evidenza *self-verifying* e adatta a contesti in cui l’audit avviene al di fuori del perimetro del sistema.

4.12.2 Export in formato PDF: report human-readable

Accanto all’export JSON (orientato alla verifica), PENTION-M fornisce un output di tipo **report** pensato per l’operatore e per attività di consultazione rapida. Nel prototipo, la generazione del report è integrata nell’interfaccia utente: a partire dall’ultimo bundle disponibile, la UI costruisce una vista strutturata che riassume i principali elementi della simulazione, tra cui: (i) identificativi e timestamp; (ii) configurazione e versioning dei modelli utilizzati; (iii) predizione di classificazione e relativa confidenza; (iv) stima di localizzazione della sorgente; (v) condizioni meteo e contesto (vento, GPS); (vi) riferimenti di integrità (hash) utili a collegare il report al bundle JSON originale.

Il PDF non sostituisce il bundle forense (che resta la *fonte primaria* per verifica e riproducibilità), ma funge da *derivato* human-readable: un “verbale tecnico” che facilita la comunicazione e l’archiviazione documentale, mantenendo un collegamento esplicito con l’evidenza crittograficamente verificabile.

4.12.3 Riproducibilità e audit esterno

Il Layer 7 è progettato per supportare **riproducibilità** e **audit esterno** senza dipendenze implicite dall’ambiente di esecuzione. In particolare, la riproducibilità è abilitata da tre scelte architetturali:

- **Serializzazione canonica dell’evento:** l’hash viene calcolato su una rappresentazione deterministica dell’evento, evitando ambiguità dovute a ordinamenti o formati.

- **Bundle auto-consistente:** l'evidenza contiene sia il contenuto (evento) sia i materiali minimi per verificarlo (hash, firma, chiave pubblica), riducendo la necessità di dipendenze esterne per controlli di integrità.
- **Separazione tra export e validazione:** le procedure di validazione e test (sviluppate a fine progetto per controlli e regressione) non sono parte del runtime operativo della pipeline, ma possono essere eseguite offline a supporto di audit e verifiche ex-post.

Autenticità dei dati e natura simulata Sebbene PENTION-M operi in un contesto simulato, è importante distinguere tra diverse tipologie di dati prodotte dal sistema. I meccanismi crittografici, le metriche di monitoring e gli output dei modelli di inferenza sono generati dinamicamente durante l'esecuzione reale della pipeline containerizzata.

Le variabili ambientali e di scenario, pur essendo simulate, sono prodotte secondo dinamiche controllate e tracciate, senza ricorso a valori statici hard-coded. Questa distinzione consente di qualificare il sistema come *data-authentic*: ogni informazione è giustificata, tracciabile e contestualizzata rispetto al suo ruolo operativo.

In sintesi, il Layer 7 completa l'architettura di PENTION-M rendendo esportabile l'intero processo decisionale: non soltanto i risultati finali, ma anche il *contesto* e le *prove di integrità* necessarie a sostenere un'analisi forense verificabile e una revisione indipendente.

4.13 Discussione architetturale e trade-off

La progettazione di PENTION-M ha richiesto una serie di scelte architetturali e modellistiche che implicano inevitabili *trade-off*. Tali scelte non sono riconducibili a un'unica dimensione di ottimizzazione, ma riflettono il tentativo di bilanciare esigenze spesso contrastanti: fedeltà fisica, accuratezza predittiva, robustezza operativa, auditabilità forense e riproducibilità.

Questa sezione discute criticamente i principali trade-off emersi durante

la progettazione e l'implementazione dell'artefatto, contestualizzandoli rispetto agli obiettivi del progetto e ai requisiti espressi dagli stakeholder.

4.13.1 Fisica vs fedeltà del modello

Un primo trade-off fondamentale riguarda il livello di fedeltà fisica della simulazione della dispersione. L'utilizzo di un modello di tipo *Gaussian Puff* come baseline fisica comporta una semplificazione significativa dei fenomeni reali di trasporto e diffusione in ambiente urbano. Come discusso nel Layer 3, la scelta del modello Gaussian Puff privilegia controllabilità e interpretabilità rispetto alla fedeltà aerodinamica fine.

Questa scelta è deliberata: l'obiettivo del modello fisico non è riprodurre con elevata accuratezza la dinamica atmosferica reale, bensì fornire una rappresentazione controllabile, interpretabile e coerente con le principali leggi fisiche. L'adozione di un modello fisico relativamente semplice consente: (i) di mantenere trasparenza sulle assunzioni effettuate; (ii) di preservare stabilità numerica e riproducibilità; (iii) di disporre di una baseline interpretabile per l'integrazione con modelli PIML.

La perdita di fedeltà fisica viene compensata dall'introduzione di un livello di correzione basato su *Physics-Informed Machine Learning*, che apprende deviazioni sistematiche rispetto alla simulazione semplificata. In questo senso, PENTION-M non persegue la massima accuratezza fisica in un singolo modello, ma una combinazione modulare di fisica esplicita e apprendimento guidato dai dati.

4.13.2 PIML vs approcci puramente data-driven

Un secondo trade-off rilevante riguarda la scelta di adottare modelli *Physics-Informed* invece di approcci puramente data-driven. I modelli data-driven offrono in genere un'elevata capacità di adattamento ai dati di training, ma soffrono di problemi di interpretabilità, generalizzazione e stabilità in contesti fisico-operativi complessi.

Nel contesto di PENTION-M, tali limiti risultano particolarmente critici: il sistema opera in un dominio cyber-fisico, in cui le predizioni devono essere compatibili con vincoli ambientali e difendibili in sede di audit. L'integrazione di feature fisiche esplicite, di vincoli nella funzione di loss e di maschere urbane consente ai modelli PIML di ridurre lo spazio delle soluzioni ammissibili, favorendo predizioni fisicamente plausibili.

Il trade-off consiste in una maggiore complessità progettuale e in una fase di training più articolata, a fronte di una maggiore robustezza e interpretabilità delle inferenze. Nel contesto applicativo considerato, questa scelta risulta coerente con i requisiti di affidabilità e tracciabilità del sistema.

4.13.3 Accuratezza vs robustezza operativa

Un ulteriore trade-off riguarda il rapporto tra accuratezza numerica e robustezza operativa. In PENTION-M, l'accuratezza delle predizioni non è l'unico criterio di qualità: la stabilità delle stime, la coerenza tra modelli, la confidenza associata agli output e il comportamento sotto rumore rivestono un ruolo altrettanto rilevante.

L'introduzione di meccanismi di monitoring runtime, di drift fisicamente informato e di metriche di stabilità riflette una visione sistemica della qualità del modello. Piuttosto che massimizzare una singola metrica offline, l'architettura privilegia la capacità del sistema di: (i) segnalare condizioni anomale; (ii) degradare in modo controllato; (iii) mantenere tracciabilità delle decisioni.

Questo approccio può portare a sacrificare marginalmente l'accuratezza puntuale in alcuni scenari, ma aumenta significativamente l'affidabilità complessiva in un contesto operativo e forense.

4.13.4 Simulazione vs dati reali

Infine, un trade-off strutturale riguarda l'utilizzo di dati simulati in luogo di dati reali. L'intero sistema opera in un contesto simulato, che consente un

controllo completo sulla *ground truth*, sulla variabilità degli scenari e sulla riproducibilità degli esperimenti.

La simulazione introduce inevitabilmente una distanza rispetto alle condizioni operative reali, ma offre vantaggi cruciali in fase di ricerca e progettazione: (i) esplorazione sistematica di scenari estremi; (ii) valutazione controllata dei modelli; (iii) possibilità di validazione *by-construction*.

L'architettura di PENTION-M è progettata in modo tale che i confini tra simulazione e possibile deployment reale siano chiaramente identificabili. I layer di ingestion, inferenza, monitoring e logging non dipendono intrinsecamente dalla natura simulata dei dati, rendendo il sistema concettualmente estendibile a contesti reali con minime modifiche infrastrutturali.

4.14 Collegamento al Capitolo di Valutazione

Il presente capitolo ha descritto in modo dettagliato l'architettura e la realizzazione di PENTION-M, mettendo in evidenza le scelte progettuali, i meccanismi di integrazione fisica e data-driven e le soluzioni adottate per garantire tracciabilità e auditabilità del sistema.

Il Capitolo 5 si colloca come naturale prosecuzione di questa analisi architeturale. La valutazione dell'artefatto non viene infatti condotta come un'analisi isolata delle prestazioni di singoli modelli, ma come una verifica sistematica delle proprietà emerse *by construction* lungo l'intero processo di progettazione.

In particolare, il capitolo di valutazione analizzerà: (i) la stabilità e l'affidabilità dei modelli PIML; (ii) il comportamento del sistema in termini di monitoring e drift; (iii) la coerenza delle predizioni rispetto ai vincoli fisici; (iv) la robustezza dei meccanismi di logging e verifica forense.

In questo modo, la valutazione non si limita a misurare risultati, ma verifica la coerenza tra obiettivi dichiarati, scelte architettureali e comportamento osservato del sistema, chiudendo il ciclo metodologico della

4. ARCHITETTURA E REALIZZAZIONE DI PENTION-M

Design Science Research adottata per lo sviluppo di PENTION-M.

CHAPTER 5

VALIDAZIONE DELL'ARTEFATTO

Questo capitolo presenta la validazione dell'artefatto PENTION-M secondo l'approccio di Design Science Research adottato. La validazione non è intesa come un singolo test finale, ma come un processo integrato e progressivo (*validation by construction*), che combina valutazione tecnica, riscontri qualitativi da parte degli stakeholder e un *experience report* sulle iterazioni di sviluppo.

5.1 Inquadramento della validazione secondo il Design Science Research

Nel paradigma della *Design Science Research* (DSR), la validazione dell'artefatto non è concepita come una fase finale isolata, ma come una componente intrinseca dell'intero processo di progettazione e sviluppo. A differenza di approcci sperimentali tradizionali, in cui la valutazione è spesso limitata alla misurazione delle prestazioni di singoli modelli o algoritmi, il DSR pone l'accento sulla capacità dell'artefatto di rispondere in modo coerente e verificabile a un problema reale, tenendo conto del contesto applicativo, dei vincoli operativi e delle esigenze degli stakeholder.

Nel caso di PENTION-M, la validazione è stata affrontata secondo un approccio di *validation by construction*, già delineato nel Capitolo 3. Tale approccio implica che le proprietà di qualità dell'artefatto — robustezza, coerenza fisica, auditabilità e usabilità operativa — non vengano valutate esclusivamente attraverso un esperimento finale, ma emergano progressivamente dalle scelte metodologiche, dalle iterazioni progettuali e dalla struttura stessa dell'architettura implementata.

Validazione dell'artefatto vs valutazione di singoli modelli

Un elemento centrale per l'inquadramento della validazione riguarda la distinzione tra la valutazione di singoli modelli e la validazione dell'artefatto nel suo complesso. Nel contesto di questa tesi, l'artefatto non coincide con un singolo modello di Machine Learning, bensì con un sistema cyber-fisico simulato che integra modellazione fisica, modelli di *Physics-Informed Machine Learning*, pipeline MLOps e meccanismi di logging forense in un flusso end-to-end coerente.

La valutazione di un modello isolato (ad esempio in termini di accuratezza, RMSE o F1-score) fornisce informazioni utili ma parziali, insufficienti a caratterizzare il comportamento del sistema in uno scenario operativo reale. Al contrario, la validazione dell'artefatto richiede di verificare proprietà sistemiche, quali: (i) la coerenza tra input fisici, inferenze e output prodotti; (ii) la stabilità del comportamento a runtime; (iii) la tracciabilità e riproducibilità delle decisioni; (iv) l'aderenza ai workflow investigativi e ai requisiti forensi.

In PENTION-M, tali proprietà non sono demandate a un singolo componente, ma distribuite lungo l'architettura a layer descritta nel Capitolo 4. La validazione assume quindi una dimensione trasversale, che attraversa l'intera pipeline e coinvolge simultaneamente scelte modellistiche, architetturali e operative.

Concetto di *validation by construction* in sistemi cyber-fisici

Il concetto di *validation by construction* risulta particolarmente appropriato nel contesto dei sistemi cyber-fisici e, in particolare, di quelli destinati a impieghi forensi e investigativi. In tali sistemi, la correttezza non può essere valutata unicamente sulla base dell'output finale, ma deve essere garantita anche rispetto al processo che conduce alla decisione.

Nel progetto PENTION-M, la validazione *by construction* si manifesta attraverso:

- l'integrazione esplicita di conoscenza fisica nei modelli di inferenza, al fine di limitare soluzioni numericamente corrette ma fisicamente implausibili;
- la separazione architetturale delle responsabilità tra simulazione, inferenza, monitoring e logging forense;
- la produzione nativa di metadati, metriche runtime ed evidenze verificabili come parte integrante dell'esecuzione della pipeline;
- l'allineamento continuo tra requisiti emersi dalla campagna di Requirements Engineering e le iterazioni dell'artefatto.

In questo quadro, la validazione non è un'attività aggiuntiva o retrospettiva, ma una proprietà emergente del modo in cui il sistema è stato progettato e realizzato. Le scelte architetturelle illustrate nel Capitolo 4 — in particolare l'introduzione di layer dedicati al monitoring, al ModelOps e al logging forense — rappresentano esempi concreti di come i criteri di validazione siano stati incorporati direttamente nella struttura dell'artefatto.

Collegamento tra requisiti, architettura e criteri di validazione

Un aspetto distintivo dell'approccio adottato è il collegamento esplicito tra requisiti, architettura e criteri di validazione. I requisiti emersi dalla

campagna di Requirements Engineering (Sezione 3.4) non sono stati trattati come semplici vincoli iniziali, ma come riferimenti costanti per guidare e valutare l'evoluzione dell'artefatto.

Ogni iterazione di PENTION-M ha tradotto specifici requisiti — operativi, tecnici, fisici e forensi — in scelte progettuali verificabili, come descritto nella Sezione 3.5. Di conseguenza, la validazione dell'artefatto consiste nel verificare la coerenza tra: (i) i requisiti dichiarati; (ii) le soluzioni architetturali adottate; (iii) il comportamento osservato del sistema durante l'esecuzione end-to-end.

Il presente capitolo si colloca quindi come naturale prosecuzione del percorso metodologico e architetturale già delineato. Le sezioni successive presenteranno la validazione dell'artefatto attraverso il confronto con gli stakeholder e l'analisi tecnica del comportamento del sistema, mostrando come le proprietà dichiarate emergano in modo coerente dal processo di progettazione seguito.

5.2 Validazione tramite stakeholder

Nel contesto della *Design Science Research*, la validazione tramite stakeholder non coincide con una nuova fase di elicitazione dei requisiti, già descritta nel Capitolo 3, ma rappresenta una forma di *valutazione ex post* dell'artefatto sviluppato. In questa prospettiva, gli stakeholder non sono considerati come fonte di input progettuali, bensì come riferimento esterno per verificare la coerenza, la credibilità e la rilevanza operativa del sistema risultante.

Per il progetto PENTION-M, il confronto con stakeholder operativi, industriali e accademici è stato utilizzato come strumento di validazione qualitativa dell'artefatto nel suo complesso. L'obiettivo non è stato quello di misurare prestazioni puntuali, ma di verificare se le scelte architetturali e metodologiche adottate risultassero plausibili, utili e giustificabili rispetto al contesto forense-investigativo di riferimento.

Questa forma di validazione è coerente con l'approccio di *validation by construction* discusso nella Sezione 5.1: le proprietà del sistema vengono valutate non come risultati isolati, ma come conseguenza diretta del modo in cui l'artefatto è stato progettato, implementato e integrato.

5.2.1 Feedback delle Law Enforcement Agencies

Il primo livello di validazione tramite stakeholder riguarda il confronto con le *Law Enforcement Agencies* (LEA), che rappresentano il principale contesto applicativo di riferimento per PENTION-M. In questa fase, l'artefatto sviluppato è stato valutato in termini di coerenza con i workflow investigativi reali, utilità percepita delle funzionalità offerte e adeguatezza delle modalità di presentazione degli output.

Dal punto di vista operativo, PENTION-M risulta coerente con le modalità di intervento tipiche delle LEA, in particolare negli scenari di pattugliamento urbano, controllo di aree logistiche e ispezione di ambienti chiusi. La pipeline end-to-end, descritta nel Capitolo 4, supporta un flusso di lavoro in cui l'analisi automatizzata fornisce indicazioni rapide e interpretabili, senza richiedere competenze specialistiche in chimica o modellazione fisica.

Un aspetto rilevante emerso dal confronto con il dominio LEA riguarda l'utilità percepita della localizzazione della sorgente e della classificazione NPS come strumenti di supporto decisionale. In particolare, la combinazione tra: (i) indicazione di presenza/assenza del segnale, (ii) stima spaziale della possibile origine, e (iii) livello di confidenza associato all'output, risulta allineata con le pratiche operative attuali, in cui l'AI è utilizzata come ausilio all'interpretazione e non come sostituto della decisione umana.

Infine, un elemento di forte rilevanza per la validazione da parte delle LEA è rappresentato dalla tracciabilità forense del processo decisionale. La possibilità di ricostruire a posteriori input, parametri di contesto, versioni dei modelli e output prodotti contribuisce a rendere il sistema compatibile con esigenze di auditabilità, catena di custodia e accountability, aspetti fondamentali in ambito investigativo.

5.2.2 Feedback dei partner industriali e di progetto

Il secondo livello di validazione tramite stakeholder riguarda il confronto con partner industriali e di progetto, il cui interesse principale è rivolto alla robustezza architetturale, alla modularità del sistema e al potenziale di integrazione futura.

Dal punto di vista architetturale, PENTION-M è stato valutato positivamente per la separazione esplicita delle responsabilità tra i diversi componenti: ingestion, simulazione fisica, modelli PIML, classificazione, monitoring e logging forense. Questa organizzazione a microservizi containerizzati, descritta nel Capitolo 4, favorisce sia la manutenibilità del sistema sia l'adattabilità a contesti operativi differenti.

Un ulteriore elemento di validazione riguarda la neutralità tecnologica dell'architettura. L'adozione di interfacce ben definite tra i moduli consente, almeno a livello concettuale, la sostituzione o l'estensione di singoli componenti (ad esempio modelli di classificazione o servizi di simulazione) senza richiedere una riprogettazione complessiva della pipeline. Questa caratteristica è particolarmente rilevante in un contesto di progetto europeo, in cui interoperabilità e riusabilità rappresentano requisiti chiave.

Nel complesso, il feedback dei partner industriali conferma che PENTION-M non è un prototipo monolitico, ma un'architettura coerente e scalabile, potenzialmente integrabile in ecosistemi più ampi di sistemi di analisi e supporto investigativo.

5.2.3 Feedback accademico e supervisione scientifica

Il terzo livello di validazione tramite stakeholder è rappresentato dalla supervisione accademica e dal confronto scientifico, che ha avuto come obiettivo principale la verifica della solidità metodologica e concettuale dell'approccio adottato.

Dal punto di vista scientifico, l'integrazione del *Physics-Informed Machine Learning* all'interno di una pipeline MLOps simulata è stata valutata

come coerente con lo stato dell'arte e adeguata al dominio applicativo considerato. In particolare, l'uso di vincoli fisici e modelli di dispersione come guida per l'inferenza contribuisce a limitare comportamenti non plausibili dei modelli data-driven, rafforzando l'interpretabilità e la robustezza del sistema.

La scelta metodologica di adottare il paradigma di *Design Science Research* è stata ritenuta appropriata per un progetto che combina ricerca applicata, sviluppo ingegneristico e confronto con stakeholder reali. La distinzione tra requisiti, progettazione dell'artefatto e validazione ex post consente di mantenere una struttura rigorosa e difendibile del lavoro di tesi.

Infine, particolare attenzione è stata posta agli aspetti di auditabilità, riproducibilità e trasparenza. La presenza di meccanismi di logging forense, versionamento dei modelli e tracciabilità end-to-end rappresenta non solo un requisito operativo, ma anche un contributo metodologico rilevante per l'adozione dell'AI in contesti forensi e investigativi.

Nel loro insieme, questi elementi confermano che PENTION-M può essere considerato un artefatto valido dal punto di vista scientifico, metodologico e applicativo, pur operando in un contesto simulato.

5.3 Validazione tecnica dell'artefatto

La validazione tecnica di PENTION-M ha lo scopo di verificare il comportamento dell'artefatto nel suo insieme, considerato come sistema cyber-fisico end-to-end, piuttosto che come collezione di modelli valutati in modo isolato. In linea con il paradigma di *Design Science Research* e con l'approccio di *validation by construction*, le attività di validazione sono state progettate per riflettere condizioni operative realistiche, pur operando in un contesto interamente simulato.

Le analisi tecniche presentate in questa sezione sono state condotte utilizzando una specifica campagna di validazione, raccolta nella cartella `validation/` del progetto. Tale campagna include test end-to-end automatizzati, stress test della pipeline MLOps e verifiche di coerenza degli

output prodotti dal sistema durante l'esecuzione completa della pipeline.

È importante sottolineare che questa fase di validazione non mira a dimostrare l'ottimalità assoluta dei singoli modelli, bensì a verificare che l'architettura progettata soddisfi requisiti fondamentali di: (i) eseguibilità end-to-end, (ii) stabilità operativa, (iii) rispetto dei vincoli temporali, (iv) coerenza dei risultati intermedi, (v) tracciabilità delle esecuzioni. La valutazione delle prestazioni specifiche dei modelli PIML, della localizzazione della sorgente e della classificazione NPS è trattata separatamente nelle sezioni successive.

5.3.1 Validazione delle prestazioni runtime

La validazione delle prestazioni runtime si concentra sull'analisi del comportamento temporale della pipeline end-to-end, con particolare attenzione alla latenza complessiva e alla compatibilità del sistema con uno scenario operativo mobile. In un contesto investigativo sul campo, la capacità di fornire output in tempi contenuti rappresenta un requisito essenziale, indipendentemente dalla qualità dei modelli sottostanti.

La pipeline di PENTION-M è stata validata mediante test end-to-end automatizzati, in cui un payload simulato completo (vettori spettrali EI, parametri ambientali, coordinate GPS del sensore e sorgente) viene inviato al servizio di ingestion e propagato attraverso tutti i layer del sistema. Durante questa esecuzione, il sistema misura e registra la latenza complessiva e le metriche di monitoraggio associate.

I test end-to-end verificano innanzitutto la corretta esecuzione della pipeline, controllando che:

- l'ingestion dei dati venga completata senza errori;
- i servizi di simulazione fisica, correzione PIML, localizzazione e classificazione producano output validi;
- il bundle forense venga generato correttamente;

- le metriche di monitoring siano disponibili a valle dell'esecuzione.

Dal punto di vista temporale, la latenza end-to-end viene misurata come intervallo tra l'invio del payload al servizio di ingestion e la ricezione della risposta finale, che include sia i risultati di inferenza sia il blocco di monitoring. Nei test automatizzati, la pipeline è considerata conforme quando la latenza complessiva rimane al di sotto di una soglia compatibile con l'uso operativo, definita a priori durante la progettazione del sistema.

Oltre ai test funzionali singoli, la validazione runtime include una campagna di stress test, in cui la pipeline viene eseguita ripetutamente con input variabili (posizione, meteo, spettri rumorosi), simulando una sequenza di eventi operativi consecutivi. Questi test consentono di osservare: (i) la stabilità delle latenze, (ii) l'assenza di degrado progressivo delle prestazioni, (iii) il comportamento dei servizi containerizzati sotto carico ripetuto.

Durante gli stress test, vengono inoltre raccolte metriche di utilizzo delle risorse dei principali container della pipeline (ingestion, monitoring, simulazione fisica, correzione PIML, localizzazione e classificazione), al fine di verificare che il costo computazionale rimanga compatibile con un'architettura mobile basata su hardware limitato. Questa analisi non ha l'obiettivo di ottimizzare le prestazioni, ma di escludere configurazioni intrinsecamente non sostenibili in uno scenario di laboratorio mobile su veicolo.

Nel complesso, i risultati dei test end-to-end e degli stress test confermano che la pipeline di PENTION-M è in grado di operare in modo stabile e ripetibile, fornendo output completi e monitorabili entro tempi compatibili con un contesto operativo simulato. Questa evidenza costituisce un prerequisito fondamentale per le successive validazioni di coerenza fisica, accuratezza spaziale e affidabilità della classificazione, che vengono analizzate nelle sezioni seguenti.

5.3.2 Validazione dei modelli PIML

Questo sottocapitolo presenta la validazione tecnica del servizio di *correzione PIML della dispersione* (CorrectionDispersion-PIML), con l'obiettivo di verificare che le mappe prodotte dal modello risultino (i) coerenti rispetto a una *ground truth* simulata di riferimento e (ii) compatibili con vincoli fisici e geometrici dello scenario urbano (in particolare la presenza di aree edificate).

In coerenza con l'impostazione *by construction* della tesi, la validazione qui descritta non mira a “massimizzare una metrica” in astratto, ma a controllare proprietà operative e fisiche che rendono l'output difendibile e interpretabile nel contesto architettuale di PENTION-M.

Setup sperimentale e pipeline di validazione

La validazione è stata eseguita tramite lo script/notebook `validation/PIML/PIML_Validation_All.ipynb`, che implementa un ciclo di test ripetuto su un insieme di scenari simulati. Per ogni simulazione:

- viene caricata una mappa di riferimento della dispersione “reale” (ground truth) dal repository dei dati simulati (`real_dispersion`);
- viene generata o recuperata la mappa di dispersione di baseline (gaussiana) e inviata al servizio di correzione PIML tramite una chiamata API (funzione helper in `validation/PIML/utils_piml.py`);
- si ottiene in output una mappa di concentrazione corretta, della stessa dimensionalità della mappa di input;
- si calcola un set di metriche fisicamente motivate (definite in `validation/PIML/metrics.py`);
- i risultati vengono aggregati e salvati in un file strutturato (`validation/PIML/validation_results_piml.csv`).

L'obiettivo del processo è quindi valutare la qualità delle mappe corrette rispetto alla ground truth e rispetto a vincoli geometrici e direzionali (vento + maschera edifici), *senza* introdurre assunzioni ulteriori non presenti nella pipeline di progetto.

Metriche di validazione

La valutazione utilizza quattro metriche, scelte per catturare aspetti complementari dell'output:

Errore RMSE su area libera (`rmse_free`). La metrica misura l'errore quadratico medio tra mappa predetta e mappa di riferimento, calcolato esclusivamente sulle celle non edificate (*free space*), utilizzando la maschera urbana. Formalmente, indicando con M la maschera binaria degli edifici e con $\Omega = \{(i, j) : M_{ij} = 0\}$ l'insieme delle celle libere:

$$\text{RMSE}_{\text{free}} = \sqrt{\frac{1}{|\Omega|} \sum_{(i,j) \in \Omega} (\hat{C}_{ij} - C_{ij})^2}.$$

Questa scelta evita che l'errore sia dominato da regioni in cui (per costruzione) la concentrazione dovrebbe risultare nulla o fortemente penalizzata.

Indice di smoothness (`smoothness`). La smoothness è un indicatore di regolarità spaziale della mappa, costruito a partire dai gradienti discreti; l'obiettivo è evidenziare la presenza di artefatti ad alta frequenza (es. discontinuità non plausibili) e caratterizzare la “stabilità spaziale” del campo predetto. In pratica, la metrica implementa un proxy di *total variation* basato sulle derivate discrete.

Allineamento al vento (`wind_alignment`). Questa metrica valuta la coerenza direzionale del campo rispetto al vento dominante. A partire dal gradiente $\nabla \hat{C}$ e dal vettore del vento $\mathbf{v} = [\cos(\theta), \sin(\theta)]$, viene calcolato un punteggio medio normalizzato basato sul prodotto scalare tra gradiente e direzione del vento (con normalizzazione per evitare dipendenze dalla scala

del gradiente):

$$s = \mathbb{E} \left[\frac{\nabla \hat{C} \cdot \mathbf{v}}{\|\nabla \hat{C}\| \cdot \|\mathbf{v}\| + \varepsilon} \right], \quad s \in [-1, 1].$$

Valori prossimi a 1 indicano una maggiore coerenza direzionale tra variazione spaziale del campo e direzione imposta dal vento, mentre valori bassi (o negativi) suggeriscono campi meno compatibili con la direzionalità attesa.

Tasso di violazione della maschera edifici (`building_violation`). La metrica stima quanta “massa” di concentrazione (in senso relativo) ricade in area edificata. È implementata come rapporto tra concentrazione cumulata sulle celle edificate e concentrazione totale della mappa:

$$\text{BV} = \frac{\sum_{i,j} \hat{C}_{ij} M_{ij}}{\sum_{i,j} \hat{C}_{ij} + \varepsilon}.$$

Un valore vicino a zero indica un’uscita compatibile con il vincolo geometrico (assenza di concentrazione nelle regioni edificate).

Risultati aggregati su campagna di simulazioni

I risultati della campagna sono salvati nel file `validation_results_piml.csv`, che contiene un record per simulazione con le quattro metriche descritte. La Tabella 5.1 riporta le statistiche principali (media, deviazione standard, minimo e massimo) calcolate sull’intero set di simulazioni.

Metrica	Media	Std	Min	Max
<code>rmse_free</code>	0.0575	0.0318	0.0067	0.2079
<code>smoothness</code>	0.0075	0.0030	0.0006	0.0183
<code>wind_alignment</code>	0.4287	0.1467	0.1132	0.7759
<code>building_violation</code>	0.0000	0.0003	0.0000	0.0031

Table 5.1: Sintesi delle metriche di validazione PIML calcolate sulle simulazioni della campagna (`validation/PIML/validation_results_piml.csv`).

Nel complesso, la metrica `building_violation` risulta prossima a zero nella quasi totalità delle simulazioni, evidenziando un comportamento coerente con il vincolo geometrico imposto dalla maschera urbana. In parallelo, il valore medio di `wind_alignment` suggerisce una coerenza direzionale apprezzabile rispetto al vento, mentre la `smoothness` rimane contenuta, indicando assenza di oscillazioni spaziali marcate nella maggior parte dei casi. L'errore `rmse_free` fornisce invece una misura diretta di scostamento dalla ground truth sulle aree osservabili non edificate, permettendo di caratterizzare in modo quantitativo la qualità del campo corretto.

Discussione e limiti

È importante sottolineare che la campagna di validazione è condotta in un contesto simulato controllato: la ground truth è generata coerentemente con lo scenario e le maschere urbane disponibili. Questo garantisce riproducibilità e consente di verificare proprietà fisiche e geometriche in modo sistematico, ma non equivale a una validazione su dati reali. Inoltre, le metriche utilizzate sono pensate per controllare *plausibilità fisica* e *compatibilità geometrica* dell'output, più che per ottimizzare un singolo indicatore globale.

Nel quadro di PENTION-M, questa validazione supporta il ruolo del CorrectionDispersion-PIML come servizio del Layer 3: l'output prodotto risulta misurabile, tracciabile e verificabile rispetto a criteri fisicamente interpretabili, costituendo una base solida per le fasi downstream della pipeline (localizzazione e reporting operativo/forense), che vengono analizzate nei sottocapitoli successivi.

5.3.3 Validazione della localizzazione della sorgente

La localizzazione della sorgente di emissione rappresenta una componente critica dell'artefatto PENTION-M, in quanto costituisce il collegamento diretto tra la modellazione della dispersione e il supporto operativo alle attività investigative. Nel contesto del paradigma di *Design Science Research*, la validazione di tale componente non è intesa come una valutazione isolata di

un singolo modello predittivo, ma come una verifica della sua adeguatezza funzionale all'interno della pipeline cyber-fisica complessiva.

In PENTION-M, la stima della posizione della sorgente è affidata a un modello di *Emission Source Localization* fisicamente informato, integrato a valle del modulo di correzione PIML della dispersione. La validazione è stata condotta utilizzando il modulo `EmissionSourceLocalization_PIML`, coerentemente con l'architettura descritta nel Capitolo 4, e si basa su scenari simulati in cui la posizione reale della sorgente è nota.

Criteri di valutazione. La qualità della localizzazione è stata valutata in termini di errore spaziale tra la posizione stimata e la posizione reale della sorgente. In particolare, sono state adottate metriche standard e direttamente interpretabili in ambito operativo:

- **Mean Absolute Error (MAE)** spaziale, espresso in metri;
- **Root Mean Square Error (RMSE)** spaziale, espresso in metri.

Tali metriche consentono di quantificare sia l'errore medio di localizzazione sia la presenza di deviazioni più marcate, fornendo una misura sintetica dell'affidabilità del sistema.

Table 5.2: Prestazioni del modello di localizzazione della sorgente ottenute tramite validazione incrociata Repeated K-Fold (5 fold, 2 ripetizioni).

Metrica	Coordinata X	Coordinata Y
RMSE (media $\pm$ std)	18.34 ± 1.59	18.48 ± 1.24
R^2 (media $\pm$ std)	0.987 ± 0.002	0.986 ± 0.002

Per analizzare in modo più approfondito il comportamento del modello di localizzazione, i risultati aggregati vengono affiancati da una rappresentazione grafica delle predizioni, al fine di valutare sia la correlazione globale tra valori reali e stimati sia la distribuzione degli errori nello spazio.

5. VALIDAZIONE DELL'ARTEFATTO




Figure 5.1: Confronto tra coordinate reali e coordinate predette dal modello di localizzazione della sorgente. La linea tratteggiata rappresenta la predizione ideale ($y = x$).

Il confronto diretto tra coordinate reali e predette evidenzia una forte correlazione lineare lungo entrambe le dimensioni spaziali. Tuttavia, tale rappresentazione non consente di cogliere la distribuzione geometrica degli errori all'interno dello scenario urbano simulato.

5. VALIDAZIONE DELL'ARTEFATTO




Figure 5.2: Confronto spaziale tra la posizione reale della sorgente e la posizione stimata dal modello PIML in scenari simulati. I segmenti rappresentano visivamente l'errore di localizzazione.




Figure 5.3: Distribuzione dell'errore euclideo di localizzazione della sorgente ottenuto durante la validazione del modello.

La distribuzione mostra una mediana dell'errore di localizzazione pari a circa 16.5 metri, con il 95% degli errori inferiori a circa 51 metri, indicando una buona stabilità delle stime spaziali nello scenario simulato.

Stabilità delle stime spaziali. I risultati aggregati della validazione, calcolati su un insieme di scenari simulati, mostrano una buona stabilità delle stime spaziali. L'errore medio assoluto si colloca nell'ordine di alcune decine di metri, mentre l'RMSE evidenzia una dispersione contenuta degli errori attorno al valore medio. Questo comportamento indica che il modello di localizzazione produce stime consistenti e non affette da instabilità numeriche o da outlier sistematici.

Dal punto di vista del sistema complessivo, tale stabilità è particolarmente rilevante, poiché la localizzazione non è utilizzata come valore puntuale assoluto, ma come informazione di supporto alla ricostruzione del contesto operativo e investigativo.

Robustezza rispetto a rumore e osservabilità parziale. La validazione è stata condotta in condizioni che riflettono implicitamente la presenza di

rumore e osservabilità parziale, tipiche degli scenari simulati di dispersione urbana. La stima della sorgente avviene infatti a partire da mappe di concentrazione corrette tramite modelli PIML, che incorporano incertezza legata a condizioni ambientali, configurazione dei sensori e geometria urbana.

I risultati ottenuti mostrano che, pur in presenza di tali fattori di incertezza, il modello di localizzazione mantiene un comportamento robusto, senza degradazioni improvvise delle prestazioni. Ciò suggerisce che l'approccio fisicamente informato contribuisce a vincolare lo spazio delle soluzioni ammissibili, riducendo l'impatto del rumore sulle stime finali.

Ordine di grandezza degli errori spaziali. L'ordine di grandezza degli errori di localizzazione osservati è coerente con le aspettative per un sistema di rilevamento mobile operante in ambiente urbano. Errori nell'ordine delle decine di metri risultano compatibili con:

- la natura indiretta del problema di localizzazione;
- l'uso di dati simulati affetti da rumore e incompletezza;
- l'obiettivo di fornire un'indicazione spaziale utile al supporto decisionale, piuttosto che una localizzazione metrica assoluta.

È stata condotta un'analisi di ablazione per valutare l'impatto delle feature di localizzazione GPS sulle prestazioni del modello. La rimozione delle coordinate GPS dall'input ha comportato un drastico peggioramento delle prestazioni, con un errore euclideo medio superiore a 160 metri. Questo risultato conferma il ruolo cruciale dell'informazione spaziale nel contesto di localizzazione mobile della sorgente e rafforza la coerenza fisica dell'approccio adottato.

In un contesto investigativo reale, tali stime sono destinate a essere integrate con ulteriori informazioni (osservazioni sul campo, dati contestuali, esperienza degli operatori), rafforzando il ruolo della localizzazione come strumento di *decision support*.

Discussione nel contesto DSR. Nel quadro della validazione *by construction* adottata in questa tesi, i risultati della localizzazione della sorgente non vengono interpretati come una dimostrazione di ottimalità del modello, bensì come evidenza della sua adeguatezza funzionale all'interno dell'artefatto PENTION-M. La coerenza delle stime, la stabilità degli errori e l'ordine di grandezza delle prestazioni contribuiscono a confermare che il modulo di localizzazione soddisfa i requisiti operativi e metodologici definiti nella fase di Requirements Engineering, completando in modo coerente il Layer di inferenza fisicamente informata della pipeline.

5.3.4 Validazione della classificazione NPS

La validazione del modulo di classificazione delle *New Psychoactive Substances* (NPS) è stata condotta con l'obiettivo di verificare l'affidabilità operativa del classificatore impiegato in PENTION-M, piuttosto che di massimizzarne le prestazioni su metriche puramente accademiche. In linea con il paradigma di *validation by construction*, l'analisi si concentra sulla qualità delle confidenze prodotte, sulla loro calibrazione e sulla robustezza del modello rispetto a perturbazioni realistiche dei dati di ingresso.

Il classificatore validato è un modello **XGBoost** addestrato su spettri EI vettorizzati, utilizzato come componente principale della pipeline decisionale. L'output del modello consiste in una predizione di classe accompagnata da una stima di confidenza, successivamente utilizzata per supportare la decisione dell'operatore umano.

Calibrazione delle confidenze Un primo aspetto critico analizzato riguarda la calibrazione delle probabilità prodotte dal modello. In contesti forensi e investigativi, una confidenza numerica non calibrata può risultare fuorviante, inducendo un'eccessiva fiducia in predizioni errate o marginali.

La Figura 5.4 mostra la curva di calibrazione ottenuta dopo l'applicazione di una strategia di *Temperature Scaling* con parametro $T = 1.8$. La curva mette in relazione la confidenza predetta dal modello con l'accuratezza empirica

osservata, consentendo di valutare lo scostamento rispetto al comportamento ideale di perfetta calibrazione.




Figure 5.4: Curva di calibrazione del classificatore XGBoost dopo Temperature Scaling ($T = 1.8$).

I risultati mostrano un buon allineamento tra confidenza predetta e accuratezza reale, in particolare nella regione di alta confidenza, che rappresenta la zona di maggiore rilevanza operativa. Il valore di *Brier score* ottenuto (≈ 0.02) conferma quantitativamente la buona qualità della calibrazione, indicando una ridotta discrepanza media tra probabilità predette ed esito corretto.

Distribuzione delle confidenze Per valutare il comportamento globale del classificatore, è stata analizzata la distribuzione delle confidenze associate alle predizioni. La Figura 5.5 evidenzia come la maggior parte delle inferenze si collochi in una regione di confidenza elevata, con una progressiva rarefazione verso valori intermedi e bassi.




Figure 5.5: Distribuzione delle confidenze prodotte dal classificatore XGBoost dopo Temperature Scaling.

Questo comportamento è coerente con uno scenario operativo in cui il sistema è chiamato a fornire indicazioni affidabili principalmente in presenza di segnali informativi sufficientemente forti, lasciando all'operatore la gestione dei casi ambigui o a bassa confidenza.

Controllo del False Alarm Rate (FAR) tramite soglie operative In un contesto operativo LEA, un requisito chiave è contenere i falsi allarmi, ovvero i casi in cui campioni non-NPS (*Other compounds*) vengono classificati come NPS. Per questo motivo, oltre alla predizione di classe, il sistema utilizza una soglia sulla probabilità complessiva di appartenenza alle classi NPS. La Tabella 5.3 mostra l'andamento del FAR al variare della soglia.

5. VALIDAZIONE DELL'ARTEFATTO

Soglia	FAR (%)	FP	TN
0.90	5.88	15	240
0.95	5.10	13	242
0.97	4.31	11	244
0.98	3.53	9	246
0.99	3.14	8	247

Table 5.3: False Alarm Rate (FAR) al variare della soglia operativa sulla probabilità complessiva di appartenenza a classi NPS.

Opzione di astensione (reject option) e copertura Per gestire i casi ambigui, il classificatore può astenersi quando la confidenza massima risulta inferiore a una soglia definita. La Tabella 5.4 riporta la copertura (percentuale di campioni classificati senza astensione) al variare della soglia di confidenza.

Soglia di confidenza	Coverage (%)
0.60	93.6
0.70	88.5
0.75	87.6
0.80	85.4

Table 5.4: Copertura del classificatore al variare della soglia di astensione (reject option).

Robustezza rispetto al rumore spettrale Un ulteriore aspetto di validazione riguarda la robustezza del classificatore rispetto a perturbazioni realistiche degli spettri di massa. A tal fine, è stato condotto un test di robustezza introducendo rumore gaussiano additivo di diversa intensità sugli spettri EI di input.

La Figura 5.6 mostra l'andamento della confidenza media al crescere del livello di rumore. I risultati indicano una degradazione graduale e controllata delle confidenze, senza collassi improvvisi del comportamento del modello.




Figure 5.6: Robustezza del classificatore NPS rispetto a rumore spettrale crescente.

Anche in presenza di livelli di rumore significativi, il modello mantiene confidenze elevate e stabili, suggerendo una buona tolleranza a condizioni di acquisizione non ideali, tipiche di scenari operativi sul campo.

Discussione qualitativa degli errori L'analisi qualitativa delle predizioni errate evidenzia come gli errori residui siano principalmente associati a:

- spettri fortemente degradati o incompleti;
- composti appartenenti a classi chimiche strutturalmente affini;
- segnali con intensità prossime alla soglia di rilevamento.

Tali casi rappresentano situazioni intrinsecamente ambigue anche per un analista umano, e risultano coerenti con l'impostazione del sistema come *decision support tool* piuttosto che come sostituto del giudizio esperto.

Nel complesso, i risultati della validazione mostrano che il classificatore NPS integrato in PENTION-M fornisce predizioni stabili, confidenze calibrate e un comportamento robusto rispetto a perturbazioni realistiche, risultando adeguato per l'impiego in una pipeline investigativa mobile e forense-ready.

5.3.5 Effetto del Temperature Scaling adattivo

Nel contesto di sistemi decisionali a supporto investigativo, la calibrazione delle probabilità associate alle predizioni riveste un ruolo cruciale. In particolare, nel caso della classificazione di Nuove Sostanze Psicoattive (NPS), la confidenza restituita dal modello non rappresenta un mero indicatore accessorio, ma costituisce parte integrante dell'evidenza forense prodotta dal sistema. Un valore di confidenza sovrastimato può infatti indurre una falsa percezione di certezza, compromettendo la correttezza dell'interpretazione operativa e la successiva utilizzabilità legale del risultato.

Durante le prime fasi di sviluppo di PENTION-M, il classificatore NPS basato su XGBoost mostrava un comportamento di marcata *overconfidence*, con probabilità frequentemente prossime all'unità anche in presenza di spettri EI degradati, rumorosi o acquisiti in condizioni ambientali sfavorevoli. Tale fenomeno è ampiamente documentato nella letteratura sui modelli di boosting e rappresenta una criticità ben nota nei sistemi di classificazione probabilistica non calibrati.

Per mitigare questo problema, è stata inizialmente introdotta una tecnica di *Temperature Scaling* post-hoc, secondo l'approccio proposto da Guo et al. [16], applicata alle probabilità prodotte dal classificatore XGBoost. In una fase preliminare, il sistema adottava un valore di temperatura fisso pari a $T = 1.8$, scelto in modo euristico al fine di ridurre i casi più evidenti di saturazione della softmax. Sebbene efficace nel contenere l'overconfidence, tale scelta non era supportata da una validazione sistematica né risultava adattabile alle diverse condizioni operative della pipeline.

Sebbene l'approccio originale preveda l'uso di un parametro di temperatura statico, ottimizzato su un dataset di validazione, nel contesto operativo di PENTION-M si è reso necessario estendere tale meccanismo verso una formulazione adattiva, in grado di riflettere la variabilità fisica e computazionale del sistema.

Successivamente, è stata condotta una fase di studio e validazione dedicata alla calibrazione, basata su un dataset di validazione costruito

ad hoc, comprendente spettri rappresentativi delle diverse classi NPS e versioni perturbate degli stessi mediante l'aggiunta di rumore controllato. Su tale dataset è stata eseguita una *sweep analysis* dei valori di temperatura nell'intervallo $[1.0, 3.0]$, valutando metriche di calibrazione quali il *Brier Score* e l'Expected Calibration Error (ECE). I risultati hanno evidenziato una regione di calibrazione ottimale compresa approssimativamente tra $T = 1.4$ e $T = 2.0$, in linea con quanto riportato nella letteratura sui modelli moderni.

Tuttavia, l'integrazione del classificatore all'interno della pipeline end-to-end di PENTION-M ha reso evidente come un valore di temperatura statico, seppur ottimale in media, non fosse sufficiente a garantire un comportamento affidabile in uno scenario operativo reale. Il sistema opera infatti in condizioni fortemente dinamiche, caratterizzate da variabilità atmosferica, turbolenza del vento, degradazione del segnale spettrale in funzione della distanza dalla sorgente, nonché da segnali diagnostici provenienti dalla pipeline MLOps, quali il drift statistico e la latenza operativa.

Alla luce di queste considerazioni, è stato progettato un meccanismo di *Temperature Scaling adattivo*, concepito come una meta-euristica ibrida in grado di modulare il valore della temperatura in funzione di diverse fonti di incertezza. Il punto di partenza è rappresentato da una temperatura di base pari a $T = 1.2$, alla quale vengono applicati incrementi controllati derivanti da:

- il livello di rumore stimato nello spettro EI;
- la classe di stabilità atmosferica secondo Pasquill;
- indicatori di coerenza fisica provenienti dal modulo PIML di correzione della dispersione;
- il drift score calcolato dal servizio di monitoring MLOps;
- la latenza end-to-end della pipeline, utilizzata come proxy della congestione computazionale e della qualità del dato.

Il valore di temperatura risultante è vincolato a rimanere all'interno dell'intervallo $[1.0, 3.0]$ ed evolve in modo continuo e stabile nel tempo, evitando oscillazioni brusche e garantendo una progressione coerente rispetto alle condizioni operative. Durante le simulazioni integrate, la temperatura adattiva ha assunto valori tipicamente compresi tra 1.2 e 2.6, dimostrando un comportamento robusto e interpretabile.

L'introduzione del Temperature Scaling adattivo ha consentito di superare in modo definitivo il problema della sovrastima probabilistica, producendo confidenze più realistiche e sensibili al contesto fisico e computazionale della pipeline. Inoltre, il valore della temperatura utilizzata in ogni inferenza viene registrato dal Monitoring Service e incluso nel bundle forense generato dal sistema, garantendo la completa tracciabilità del processo di calibrazione. Ciò consente, in fase di audit, di ricostruire non solo la predizione finale, ma anche il livello di incertezza che ha accompagnato l'analisi, soddisfacendo i requisiti di trasparenza e verificabilità richiesti in ambito investigativo.

Nel complesso, questa fase ha trasformato il classificatore NPS da un modello affetto da overconfidence strutturale ad un componente pienamente integrato in una pipeline PIML+MLOps, dotato di un meccanismo di calibrazione probabilistica scientificamente fondato, validato sperimentalmente e coerente con le esigenze forensi di PENTION-M.

5.4 Experience Report

Questa sezione presenta un *experience report* focalizzato sul processo di progettazione e sviluppo dell'artefatto PENTION-M, con l'obiettivo di esplicitare come le iterazioni progettuali abbiano costituito una forma di *validazione by construction*. In coerenza con il paradigma del Design Science Research, l'esperienza non viene intesa come un resoconto cronologico dello sviluppo, bensì come un'analisi riflessiva delle decisioni progettuali che hanno guidato l'evoluzione dell'artefatto verso la configurazione finale validata.

5.4.1 Contesto dell'esperienza di sviluppo

Lo sviluppo di PENTION-M si è svolto all'interno del progetto europeo PENTION, con l'obiettivo di realizzare un sistema di supporto investigativo per la rilevazione e l'identificazione di sostanze, incluse le New Psychoactive Substances (NPS), in scenari operativi delle Law Enforcement Agencies (LEAs). A differenza di un progetto puramente accademico, il contesto ha imposto vincoli realistici legati alla plausibilità operativa, alla tracciabilità forense e alla necessità di produrre un artefatto dimostrabile.

Un elemento strutturale del contesto è stato il passaggio concettuale da PENTION-S, sistema stazionario sviluppato in precedenza, a PENTION-M, concepito come laboratorio mobile installato su van. Questo cambiamento non è stato affrontato come una semplice estensione funzionale, ma come una riprogettazione dell'intera pipeline end-to-end, includendo simulazione fisica, modelli PIML, servizi di inferenza, MLOps, interfaccia operativa e produzione di evidenze forensi.

Dal punto di vista progettuale, lo sviluppo è stato caratterizzato da: (i) requisiti progressivamente raffinati tramite attività di Requirements Engineering con stakeholder reali; (ii) necessità di bilanciare rigore metodologico (DSR, auditabilità, riproducibilità) e concretezza implementativa; (iii) vincoli temporali tipici di un progetto di tesi integrato in un contesto di ricerca applicata. Questi elementi hanno reso necessario un approccio iterativo, in cui l'evoluzione dell'artefatto e la sua validazione procedessero in modo congiunto.

5.4.2 Problemi emersi durante la costruzione dell'artefatto

Nel corso dello sviluppo sono emerse criticità che non possono essere interpretate come semplici difetti implementativi, ma come indicatori di fragilità strutturale dell'artefatto rispetto ai requisiti operativi e forensi.

Un primo insieme di problemi ha riguardato la coerenza fisica e operativa

degli output generati dalla pipeline. Le prime versioni del sistema, basate su modelli fisici e data-driven non integrati, mostravano comportamenti instabili o poco plausibili in condizioni degradate (rumore, osservabilità parziale, variabilità ambientale), evidenziando la necessità di un'integrazione più profonda tra conoscenza fisica e apprendimento automatico.

Una seconda criticità ha riguardato l'affidabilità delle inferenze probabilistiche, in particolare per la classificazione NPS. L'emergere di fenomeni di *overconfidence* ha reso evidente che l'accuratezza del modello non fosse sufficiente a garantire l'utilizzabilità investigativa del risultato, richiedendo meccanismi espliciti di calibrazione e controllo dell'incertezza.

Infine, sono emersi problemi legati alla verificabilità e alla ricostruibilità delle decisioni del sistema. In assenza di un logging strutturato e di un audit trail completo, l'artefatto rischiava di rimanere una "demo tecnica", non idonea a contesti forensi in cui esiti e confidenze devono poter essere giustificati a posteriori.

5.4.3 Iterazioni progettuali come forma di validazione

Le soluzioni adottate a fronte delle criticità emerse non sono state introdotte come aggiunte isolate, ma come iterazioni progettuali mirate, ciascuna delle quali ha contribuito alla validazione dell'artefatto per costruzione.

L'introduzione dell'approccio PIML ha rappresentato una prima iterazione strutturale, finalizzata a stabilizzare le inferenze fisiche e a ridurre la produzione di output non plausibili. L'integrazione di feature fisiche, vincoli e controlli di coerenza ha consentito di migliorare la robustezza del sistema senza sacrificare la capacità predittiva dei modelli.

Una successiva iterazione ha riguardato la calibrazione delle confidenze del classificatore NPS, culminata nell'introduzione di un meccanismo di Temperature Scaling adattivo. Questa scelta ha trasformato la stima probabilistica da output statico a misura contestualizzata della qualità dell'inferenza, rendendo la confidenza parte integrante dell'evidenza prodotta.

Parallelamente, l'introduzione sistematica di servizi di monitoring e logging forense ha rappresentato un ulteriore passo di validazione. La registrazione di parametri di contesto, segnali diagnostici e metadati di inferenza ha reso possibile ricostruire il comportamento del sistema end-to-end, soddisfacendo requisiti di auditabilità e tracciabilità tipici dei domini investigativi.

In questo senso, ogni iterazione non ha solo migliorato una componente tecnica, ma ha ridotto un rischio specifico rispetto ai requisiti operativi e forensi, rafforzando progressivamente la validità complessiva dell'artefatto.

5.4.4 Lezioni metodologiche apprese

L'esperienza di sviluppo di PENTION-M consente di trarre alcune lezioni metodologiche rilevanti per la progettazione di sistemi PIML integrati in pipeline cyber-fisiche e forensi.

In primo luogo, la validazione in contesti investigativi non può essere confinata a una fase finale di test, ma deve essere incorporata nelle scelte architetturali e nei meccanismi di esecuzione del sistema. Logging, tracciabilità e riproducibilità non sono requisiti accessori, ma condizioni necessarie affinché l'artefatto sia valutabile.

In secondo luogo, l'efficacia del PIML non deriva dall'aumento della complessità teorica, ma dalla collocazione mirata della conoscenza fisica nei punti di maggiore fragilità del modello. L'integrazione selettiva di vincoli e feature fisiche si è dimostrata più efficace di approcci puramente data-driven o rigidamente fisici.

Infine, l'esperienza conferma che in pipeline operative complesse il monitoring e la gestione dell'incertezza costituiscono parte integrante del comportamento atteso del sistema. La capacità di osservare drift, degradazione e qualità dell'inferenza è un requisito fondamentale per garantire affidabilità nel tempo.

Nel complesso, il processo di sviluppo di PENTION-M mostra come un approccio DSR, supportato da iterazioni progettuali consapevoli, possa

condurre alla realizzazione di un artefatto non solo funzionante, ma progettato per essere validabile, interpretabile e coerente con i requisiti di un dominio forense.

5.5 Discussione complessiva dei risultati

La validazione dell'artefatto PENTION-M, condotta secondo il paradigma del Design Science Research, ha evidenziato un quadro complessivamente coerente e positivo rispetto agli obiettivi definiti nei capitoli precedenti. I risultati presentati nelle Sezioni 5.2 e 5.3 mostrano come la pipeline end-to-end sia in grado di operare in modo stabile, tracciabile e plausibile all'interno dello scenario simulato di riferimento, integrando modelli fisici, componenti PIML e servizi MLOps in un unico artefatto funzionale.

Dal punto di vista tecnico, la validazione ha confermato la correttezza dell'integrazione architetturale: la simulazione fisica fornisce input coerenti ai moduli di inferenza, i modelli PIML contribuiscono a migliorare la stabilità e la plausibilità degli output, e i servizi di monitoring e logging garantiscono osservabilità, auditabilità e riproducibilità delle inferenze. La pipeline risulta quindi non solo “funzionante”, ma progettata esplicitamente per essere verificabile, in linea con i requisiti di contesti investigativi e forensi.

È importante sottolineare che PENTION-M non rappresenta un'evoluzione incrementale di PENTION-S, bensì un artefatto distinto, concepito per operare in scenari dinamici e mobili, complementari a quelli statici affrontati dalla versione precedente. Di conseguenza, i risultati ottenuti non vengono interpretati in termini di confronto diretto tra i due sistemi, ma come dimostrazione della fattibilità e coerenza di una soluzione specificamente progettata per il contesto operativo del “mobile lab”.

Nel complesso, la validazione by construction supporta l'ipotesi che l'architettura proposta sia adeguata allo scopo, che le scelte progettuali siano giustificate dai requisiti raccolti e che il sistema mostri un comportamento robusto e interpretabile nelle condizioni simulate. Al tempo stesso, l'analisi

dei risultati ha reso espliciti alcuni limiti strutturali, legati principalmente alla natura simulata dei dati e all'assenza di sperimentazione sul campo, che non compromettono la validità dell'artefatto ma ne delimitano il perimetro applicativo.

Queste considerazioni costituiscono il naturale punto di transizione verso il Capitolo 6, in cui tali limitazioni vengono analizzate in modo sistematico e utilizzate come base per delineare possibili sviluppi futuri del sistema.

CHAPTER 6

LIMITAZIONI E SVILUPPI FUTURI

ACKNOWLEDGEMENTS

REFERENCES

- [1] European Monitoring Centre for Drugs and Drug Addiction. *Understanding the ‘New Psychoactive Substances’ Phenomenon*. Lisbon, Portugal: EMCDDA, 2023. url: https://www.emcdda.europa.eu/topics/nps_en.
- [2] United Nations Office on Drugs and Crime. *World Drug Report 2023*. United Nations, 2023. url: <https://www.unodc.org/unodc/index.html>.
- [3] Jürgen H. Gross. *Mass Spectrometry: A Textbook*. 3rd ed. Springer, 2017. doi: 10.1007/978-3-319-54398-7. url: <https://link.springer.com/book/10.1007/978-3-319-54398-7>.
- [4] Scientific Working Group for the Analysis of Seized Drugs. *SWGDRUG Mass Spectral Library*. Accessed 2024. 2024. url: <https://www.swgdrug.org/ms.htm>.
- [5] MassBank of North America. *MoNA: MassBank of North America*. Open-access mass spectral database. 2024. url: <https://mona.fiehnlab.ucdavis.edu>.
- [6] National Institute of Advanced Industrial Science and Technology. *Spectral Database for Organic Compounds (SDBS)*. Japanese national spectral database. 2024. url: <https://sdb.db.aist.go.jp>.

REFERENCES

- [7] D. Bruce Turner. *Workbook of Atmospheric Dispersion Estimates*. 2nd ed. CRC Press, 1994. isbn: 978-1566700238. url: <https://www.routledge.com/Workbook-of-Atmospheric-Dispersion-Estimates/Turner/p/book/9781566700238>.
- [8] George Em Karniadakis et al. “Physics-informed machine learning”. In: *Nature Reviews Physics* 3 (2021), pp. 422–440. doi: 10.1038/s42254-021-00314-5. url: <https://www.nature.com/articles/s42254-021-00314-5>.
- [9] Xiangyu Meng, Zongyi Li, and George Em Karniadakis. “Physics-informed neural networks (PINNs): Theory and applications”. In: *Journal of Computational Physics* 398 (2020), p. 108884. doi: 10.1016/j.jcp.2019.108884. url: <https://doi.org/10.1016/j.jcp.2019.108884>.
- [10] Chuizheng Meng et al. “When physics meets machine learning: A survey of physics-informed machine learning”. In: *Machine Learning for Computational Science and Engineering* 1.1 (2025), p. 20.
- [11] K. Kashinath et al. “Physics-informed machine learning: case studies for weather and climate modelling”. In: *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences* 379.2194 (Feb. 2021), p. 20200093. issn: 1364-503X. doi: 10.1098/rsta.2020.0093. url: <https://doi.org/10.1098/rsta.2020.0093>.
- [12] Mouhammad El Hassan et al. “Machine Learning in Fluid Dynamics—Physics-Informed Neural Networks (PINNs) Using Sparse Data: A Review”. In: *Fluids* 10.9 (2025). issn: 2311-5521. doi: 10.3390/fluids10090226. url: <https://www.mdpi.com/2311-5521/10/9/226>.
- [13] Nanzhe Wang, Yuntian Chen, and Dongxiao Zhang. *A comprehensive review of physics-informed deep learning and its applications in geoenery development*. 2025. doi: 10.59717/j.xinn-energy.2025.100087. url: <https://www.the-innovation.org/energy/article/id/67f9cd093e5ee924414bf3a4>.

REFERENCES

- [14] Leonhard Faubel-Teich, Klaus Schmid, and Holger Eichelberger. “MLOps Challenges in Industry 4.0”. In: *SN Computer Science* 4.6 (2023), pp. 1–11. doi: 10.1007/s42979-023-02282-2. url: <https://doi.org/10.1007/s42979-023-02282-2>.
- [15] Fabio Calefato, Filippo Lanubile, and Luigi Quaranta. “Security Risks and Best Practices of MLOps: A Multivocal Literature Review”. In: *Proceedings of the Italian Conference on Cyber Security (ITASEC 2024)*. Vol. 3731. CEUR Workshop Proceedings. Open access. 2024. url: <https://ceur-ws.org/Vol-3731/paper13.pdf>.
- [16] Chuan Guo et al. *On Calibration of Modern Neural Networks*. 2017. arXiv: 1706.04599 [cs.LG]. url: <https://arxiv.org/abs/1706.04599>.

LIST OF FIGURES

3.1	Data Flow Model del processo di Design Science Research adottato per il progetto PENTION-M.	42
4.1	Architettura a 8 layer di PENTION-M e flusso end-to-end del sistema.	47
4.2	Distribuzione delle principali variabili fisiche utilizzate nel dataset PIML, incluse velocità del vento, indice di stabilità atmosferica e umidità relativa. Gli intervalli mostrati riflettono condizioni atmosferiche realistiche coerenti con lo scenario simulato.	58
4.3	Matrice di correlazione tra le feature fisiche e le feature di interazione utilizzate dal modello PIML per la localizzazione della sorgente. Le correlazioni osservate riflettono relazioni coerenti con i meccanismi fisici di dispersione atmosferica e con la struttura delle feature derivate.	60
4.4	Accuratezza dei modelli valutati nella fase di selezione del classificatore NPS sul dataset PENTION_EI_Complete.	62

LIST OF FIGURES

4.5	Importanza relativa delle feature spettrali selezionate tramite Recursive Feature Elimination (RFE) per il classificatore NPS. Le feature evidenziate risultano coerenti con contributi EI fisicamente e chimicamente interpretabili.	63
4.6	Matrice di confusione del classificatore XGBoost (fase di selezione e integrazione del servizio).	63
5.1	Confronto tra coordinate reali e coordinate predette dal modello di localizzazione della sorgente. La linea tratteggiata rappresenta la predizione ideale ($y = x$).	103
5.2	Confronto spaziale tra la posizione reale della sorgente e la posizione stimata dal modello PIML in scenari simulati. I segmenti rappresentano visivamente l'errore di localizzazione. .	104
5.3	Distribuzione dell'errore euclideo di localizzazione della sorgente ottenuto durante la validazione del modello.	105
5.4	Curva di calibrazione del classificatore XGBoost dopo Temperature Scaling ($T = 1.8$).	108
5.5	Distribuzione delle confidenze prodotte dal classificatore XGBoost dopo Temperature Scaling.	109
5.6	Robustezza del classificatore NPS rispetto a rumore spettrale crescente.	111

LIST OF TABLES

2.1	Distribuzione delle classi chimiche nel dataset PENTION_EI_Complete.	22
2.2	Esempio di rappresentazione vettoriale degli spettri EI nel dataset PENTION_EI_Complete.	23
3.1	Sintesi consolidata dei requisiti emersi dalla campagna di Requirements Engineering (questionari e workshop LEAs) e loro mapping su PENTION-M.	35
4.1	Struttura concettuale del dataset PIML e origine delle feature utilizzate nei modelli di inferenza.	57
5.1	Sintesi delle metriche di validazione PIML calcolate sulle simulazioni della campagna (validation/PIML/validation_results_piml.csv).	100
5.2	Prestazioni del modello di localizzazione della sorgente ottenute tramite validazione incrociata Repeated K-Fold (5 fold, 2 ripetizioni).	102
5.3	False Alarm Rate (FAR) al variare della soglia operativa sulla probabilità complessiva di appartenenza a classi NPS.	110

LIST OF TABLES

5.4	Copertura del classificatore al variare della soglia di astensione (reject option).	110
-----	--	-----